Anexo G: Conjunto de datos maestro DERMATEC

Este anexo documenta la construcción del conjunto de datos usado para entrenar, validar y evaluar el clasificador de DERMATEC: las fuentes, los filtros aplicados, la composición por clase y el procedimiento de partición usado para reducir la fuga de información. El conjunto final quedó guardado como DERMATEC_KAGGLE_V2 y alojado como conjunto de datos privado en Kaggle. Los manifiestos, los metadatos y el código están en la carpeta GITHUB/01_dataset del repositorio del proyecto.

G.1. Evolución del conjunto de datos

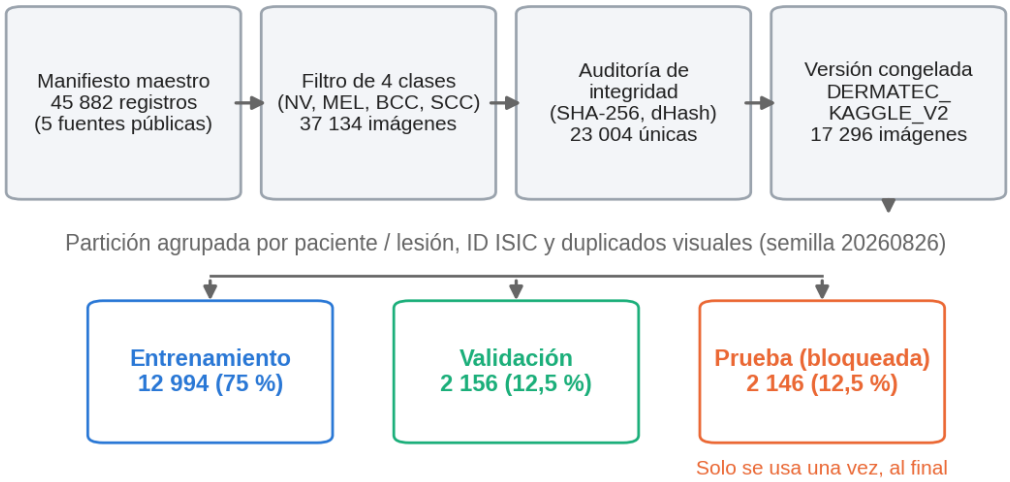
El conjunto se construyó en varias etapas. Se partió de un manifiesto maestro de 45.882 registros que unificó ISIC 2019 (Codella et al., 2018; Combalia et al., 2019; International Skin Imaging Collaboration, 2019), HAM10000 (Tschandl et al., 2018), DERM12345 (Yilmaz et al., 2024), la colección HIBA (Ricci Lara et al., 2023) y tres colecciones del archivo ISIC separadas por modalidad. Antes de quitar los registros repetidos por identificador de imagen entre fuentes había 57.180. MILK10k (MILK study team, 2025; Tschandl et al., 2026) no forma parte de esos 45.882 registros: se incorporó después, en la curaduría (G.6).

Al conservar solo nevo, melanoma, carcinoma basocelular y carcinoma escamocelular quedaron 37.134 imágenes, 29.403 de ellas nevos. La reducción a 23.006 no se debe a la depuración de duplicados ni de archivos dañados, sino a dos decisiones sobre la composición: se conservaron 12.000 nevos y todas las lesiones malignas (19.731 imágenes; se retiraron 17.403 nevos) y se incorporaron 3.275 dermatoscopías de MILK10k, casi todas carcinomas. Así se llegó a 23.006 imágenes (12.000 NV, 4.542 MEL, 5.168 BCC y 1.296 SCC). En la lectura de los archivos no hubo imágenes faltantes ni sin clase válida. La auditoría por SHA-256 encontró después dos pares de copias exactas; al retirar una de cada par quedaron 23.004 imágenes únicas.

Una primera versión del paquete de entrenamiento (V1, 20.091 imágenes) incluía 46 columnas de características derivadas, pero perdía el vínculo con los identificadores originales, lo que impedía verificar la partición. Por eso se reemplazó por DERMATEC_KAGGLE_V2, que contiene solo imágenes originales y manifiestos de trazabilidad, sin máscaras, ROI ni vectores precalculados. En V2 se incluyeron todos los SCC y se fijaron 4.500 MEL, 4.500 BCC y 7.000 NV, para un total de 17.296 imágenes. BCN20000 no se añadió como fuente aparte por su alto solapamiento con ISIC 2019.

Figura 1.

Evolución del conjunto de datos desde el manifiesto inicial hasta la versión congelada



Nota. Registro de filtrado y depuración lógica de muestras. Creado por autores.

G.2. Fuentes y modalidades de captura

Se buscó representar varias modalidades de adquisición (polarizada y no polarizada, con y sin contacto) para que el modelo no aprenda patrones propios de un único dispositivo. MILK10k aportó principalmente carcinomas confirmados por histopatología (ver Tabla 1 y Figura 2). Tres fuentes no aportan ningún nevo: MILK10k, DERM12345 y HIBA suman 3.960 imágenes (22,9 % del conjunto), todas malignas. En MILK10k se debe al filtro de incorporación, que no tomó nevos; en DERM12345, a la selección por cupos, que dejó fuera sus 2.914 nevos (G.7); las 227 imágenes de HIBA son todas malignas. Esta composición se discute como limitación en G.11.

Tabla 1.

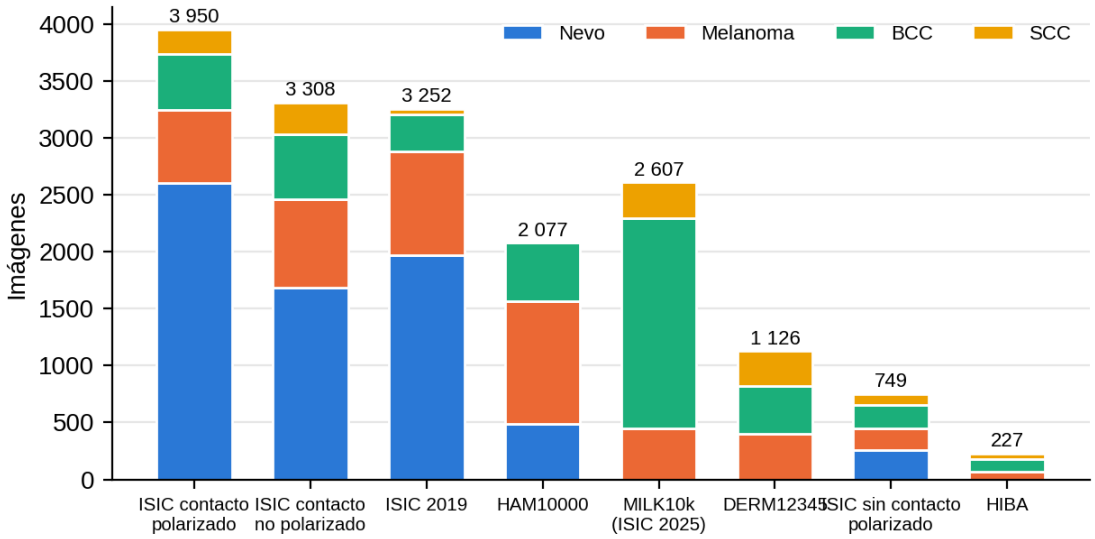
Imágenes por fuente y clase en DERMATEC_KAGGLE_V2

Fuente	Modalidad	NV	MEL	BCC	SCC	Total
ISIC, contacto polarizado	Polarizada, contacto	2.601	644	488	217	3.950
ISIC, contacto no polarizado	No polarizada, contacto	1.686	771	577	274	3.308
ISIC 2019	Mixta	1.968	908	327	49	3.252
HAM10000	Mixta	491	1.072	514	0	2.077
MILK10k (ISIC 2025)	Mixta	0	446	1.850	311	2.607
DERM12345	Polarizada	0	400	423	303	1.126
ISIC, sin contacto polarizado	Polarizada, sin contacto	254	194	207	94	749
HIBA	Fotografía clínica	0	65	114	48	227
Total		**7.000**	**4.500**	**4.500**	**1.296**	**17.296**

Nota. Conteos del archivo pack_info.json del paquete congelado. Mixta: la fuente reúne varios dermatoscopios y no reporta la modalidad por imagen. Las 227 imágenes de HIBA figuran en el manifiesto como fotografías clínicas (image_type “clinical: overview” o “clinical: close-up”) y sin tipo de luz; sus dermatoscopías ya habían entrado por el subconjunto ISIC de contacto polarizado (ver G.11). Creado por autores.

Figura 2.

Composición del conjunto de datos por fuente y clase diagnóstica



Nota. Distribución acumulada de imágenes por fuente en el conjunto DERMATEC. Creado por autores.

G.3. Partición sin fuga de información

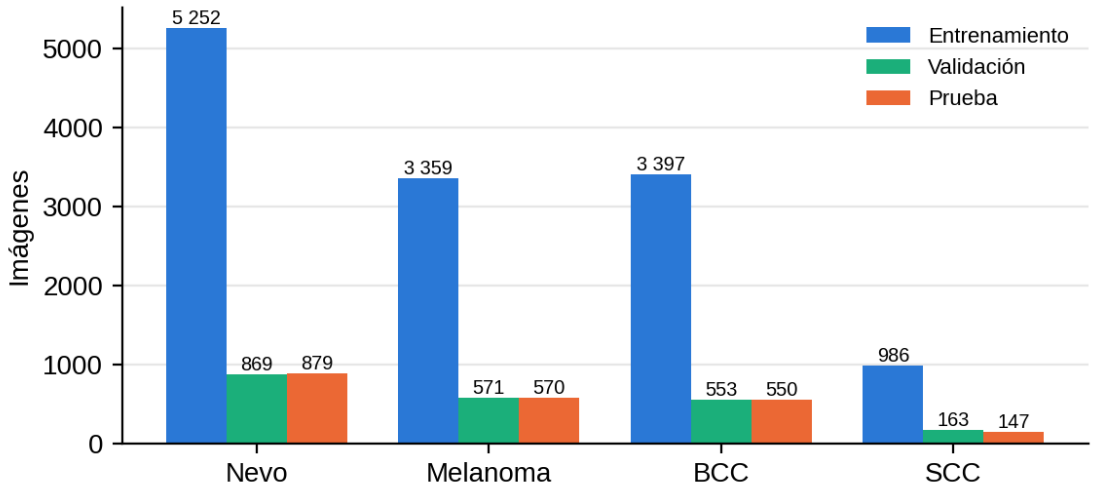
La partición se hizo por grupos y con semilla fija (20260826): dentro de cada fuente se agruparon las imágenes por paciente y lesión cuando la fuente lo permite, se unificaron los identificadores ISIC repetidos entre colecciones y los duplicados visuales se mantuvieron juntos. El resultado fue 12.994 imágenes de entrenamiento, 2.156 de validación y 2.146 de prueba (Figura 3). El conjunto de prueba no se usó para entrenar ni para elegir épocas. La elección del modelo final y su calibración (sesgo por clase, umbral de malignidad y uso de TTA) se hicieron solo con validación. En la serie de robustez el conjunto de prueba se evaluó en cada experimento; por eso en el Anexo K se reportan sus resultados para todos los modelos y no solo para el elegido. Antes de cada entrenamiento, el código verifica los conteos, las etiquetas y la ausencia de coincidencias entre particiones:

```
for nombre, df in [("train", train_df), ("validation", val_df)]:
    assert len(df) == CONTEOS_ESPERADOS[nombre]
    assert set(df["indice_clase_4"].astype(int)) == {0, 1, 2, 3}

for col in ["image_relpath", "sha256", "group_id_split"]:
    fuga = set(train_df[col].astype(str)) & set(val_df[col].astype(str))
    assert not fuga, f"Fuga Train/Validation en {col}: {len(fuga)}"
```

Figura 3.

Distribución por clase en las particiones de entrenamiento, validación y prueba



Nota. Partición formal de DERMATEC_KAGGLE_V2 con aislamiento de grupos. Creado por autores.

G.4. Por qué se combinaron varias fuentes

Hubo dos razones. La primera es la cantidad de imágenes por clase. El proyecto clasifica cuatro lesiones y ninguna base pública reunía suficientes imágenes de todas. HAM10000 no tiene SCC como clase propia, ISIC 2019 aporta solo 49 SCC a este conjunto y la fuente con más SCC, MILK10k, aporta 311 de los 1.296 finales. Antes de cerrar la recolección se buscó en todo el ISIC Archive: había 349 SCC invasivos dermatoscópicos con histopatología y los 349 ya estaban incluidos. Seguir descargando solo habría sumado más BCC y melanomas y aumentado el desbalance, por eso la recolección se detuvo ahí.

La segunda es la modalidad de captura. Si la red se entrena con imágenes de un solo tipo de iluminación, su desempeño puede caer al cambiar de equipo. Combinar fuentes trajo imágenes repetidas entre colecciones (ISIC 2019 contiene HAM10000, BCN20000 y MSK; el ISIC Archive contiene HIBA y HAM10000), nombres de diagnóstico distintos en cada fuente y un desbalance alto entre clases. Las secciones G.6 y G.7 describen cómo se trató cada uno.

G.5. Obtención de las fuentes

Las descargas se hicieron en Google Colab con el notebook Datasets.ipynb. Las imágenes del ISIC Archive se bajaron con la herramienta oficial de línea de comandos, filtrando por el campo dermoscopic_type (International Skin Imaging Collaboration [ISIC], s. f.); HIBA, DERM12345 y MILK10k, desde su página DOI en el mismo archivo (MILK study team, 2025);

HAM10000 e ISIC 2019, desde copias publicadas en Kaggle de los conjuntos oficiales (Codella et al., 2018; Combalia et al., 2019; International Skin Imaging Collaboration, 2019). También se descargó la colección MSK-2, que se descartó por no documentar la modalidad de captura, y se revisó PH2, que no se usó (Tabla 2).

Tabla 2.

Fuentes, forma de obtención y aporte al conjunto final

Fuente	Cómo se obtuvo	Registros en el manifiesto	En el conjunto final
DERM12345	ISIC Archive, DOI 10.34970/705541	12.345	1.126
ISIC, contacto polarizado	Filtro por modalidad	11.516	3.950
HAM10000	Copia en Kaggle del conjunto oficial	10.015	2.077
ISIC, contacto no polarizado	Filtro por modalidad (máx. 5.000)	5.000	3.308
ISIC 2019	Copia en Kaggle del reto ISIC 2019	4.334	3.252
ISIC, sin contacto polarizado	Filtro por modalidad	2.317	749
HIBA	ISIC Archive, DOI 10.34970/559884	355	227
MILK10k	ISIC Archive, DOI 10.34970/648456	3.275 incorporadas	2.607
Total		**45.882 + 3.275**	**17.296**

Nota. Las 1.280 dermatoscopías de HIBA (de 1.635 registros) ya estaban en el subconjunto ISIC de contacto polarizado; por eso HIBA solo suma 355 registros propios, que son fotografías clínicas. De la copia de ISIC 2019 se cargaron 14.352 registros; al quitar los que repetían identificador de imagen con HAM10000 y con los subconjuntos ISIC quedaron 4.334. MILK10k no está en los 45.882 registros del manifiesto porque se incorporó en la curaduría (G.6). Fuentes: Datasets.ipynb y pack_info.json. Creado por autores.

G.6. Curaduría por etapas

En los primeros experimentos de la red, el conjunto de entrenamiento (33.778 imágenes, después de apartar validación y prueba) tenía 27.347 nevos frente a 710 SCC, unos 38 nevos por cada SCC. Por eso el SCC aparece con 710 imágenes en esos experimentos y con 985 en la Tabla 3, que cuenta las cuatro clases antes de partir. Para reducir ese desbalance se pasó de 29.403 a 12.000 nevos y se conservaron todas las lesiones malignas (19.731 imágenes). Luego se calcularon dos huellas para cada imagen. SHA-256 identifica copias exactas del archivo y dHash de 64 bits identifica imágenes visualmente iguales aunque estén recomprimidas o redimensionadas. Un dHash igual no prueba que sean la misma imagen; por eso, dentro del conjunto, se usó para agrupar y no para borrar. La única excepción fueron cuatro candidatas de MILK10k que coincidían por dHash con imágenes ya presentes y no se incorporaron.

En la misma etapa se incorporó MILK10k porque todas sus lesiones tienen confirmación histopatológica y aporta carcinomas, la clase más escasa (Tschandl et al., 2026). Esta base trae, para cada lesión, una foto clínica y una dermatoscopía; se tomó solo la dermatoscopía y solo los casos con histopatología de BCC, melanoma y SCC invasivo. Se excluyeron los queratoacantomas (162) y los SCC in situ o enfermedad de Bowen (180). De 3.279 candidatas no hubo coincidencias por identificador ni por SHA-256 con el conjunto previo; cuatro coincidieron por dHash y se dejaron fuera. Entraron 3.275 imágenes (446 MEL, 2.518 BCC y 311 SCC) y el conjunto llegó a 23.006. La auditoría final encontró dos pares de copias exactas con la misma etiqueta; al quitar una de cada par quedaron 23.004 imágenes únicas (Tabla 3).

Tabla 3.

Imágenes por clase en cada etapa

Etapa	NV	MEL	BCC	SCC	Total
Cuatro clases objetivo	29.403	4.096	2.650	985	37.134
Depuración (12.000 nevos + malignas)	12.000	4.096	2.650	985	19.731
Aporte de MILK10k	—	+446	+2.518	+311	+3.275
Conjunto curado	12.000	4.542	5.168	1.296	23.006
Sin copias exactas	11.999	4.541	5.168	1.296	23.004
Excluidas por cupo	−4.999	−41	−668	0	−5.708
DERMATEC_KAGGLE_V2	**7.000**	**4.500**	**4.500**	**1.296**	**17.296**

Nota. Las 5.708 excluidas por cupo más las 2 copias exactas son las 5.710 filas de manifest_DERMATEC_KAGGLE_V2_excluidas.csv. Creado por autores.

G.7. Selección final por cupos

Con 23.004 imágenes disponibles se fijaron cupos por clase: todos los SCC (1.296), 4.500 melanomas, 4.500 BCC y 7.000 nevos. El cupo de nevos se eligió para que esa clase no dominara el entrenamiento: con él quedan unos 5 nevos por cada SCC, frente a 38 en los experimentos previos.

Para decidir qué imágenes entraban en cada clase, primero se agruparon las fotos de una misma lesión (por identificador de lesión; si no había, por identificador ISIC; si no, por SHA-256), de modo que una lesión entra o sale completa. Luego cada grupo recibió el puntaje $100 \cdot r + 0{,}02 \cdot t + u$, donde r es la rareza media de su combinación de fuente, polarización y contacto dentro de la clase ($1/\sqrt{n}$, con n el número de imágenes de esa combinación), t es la trazabilidad (3 puntos por identificador de lesión, 2 por el de paciente, 2 por el ISIC y 1 por cada modalidad conocida, máximo 9) y u es un número aleatorio entre 0 y 1 con semilla fija. Como la trazabilidad suma como mucho 0,18, la rareza define el orden entre combinaciones y, dentro de una misma combinación, el orden es casi aleatorio. Los grupos se tomaron en orden de puntaje

hasta completar el cupo exacto. Quedaron fuera 4.999 nevos (todos los de DERM12345, 1.993 de HAM10000 y 92 del subconjunto ISIC de contacto polarizado), 41 melanomas de HAM10000 y 668 BCC de MILK10k. Al favorecer las combinaciones poco representadas, la selección retiró todos los nevos de DERM12345, una fuente que sí tiene nevos.

G.8. Modalidad de captura

La Tabla 4 resume la modalidad registrada. Un tercio de las imágenes es polarizada, una quinta parte no polarizada y casi la mitad no tiene la modalidad documentada, porque HAM10000, ISIC 2019 y MILK10k no la reportan por imagen y las 227 imágenes de HIBA son fotografías clínicas sin tipo de luz (2.077 + 3.252 + 2.607 + 227 = 8.163). DERM12345 se cuenta como polarizada porque la fuente lo declara para todo el conjunto, pero no documenta el contacto. La combinación polarizada sin contacto es la menos representada, con 749 imágenes (4,3 %).

Tabla 4.

Modalidad de captura por clase

Modalidad	NV	MEL	BCC	SCC	Total	%
Polarizada	2.855	1.238	1.118	614	5.825	33,7
No polarizada	1.686	771	577	274	3.308	19,1
Polarización desconocida	2.459	2.491	2.805	408	8.163	47,2
Con contacto	4.287	1.415	1.065	491	7.258	42,0
Sin contacto	254	194	207	94	749	4,3
Contacto desconocido	2.459	2.891	3.228	711	9.289	53,7

Nota. Las tres primeras filas suman 17.296, y las tres últimas también. Creado por autores.

G.9. Detalle del procedimiento de partición

Se unieron en un mismo grupo las imágenes que compartían alguno de estos datos: grupo de lesión de la etapa anterior, paciente dentro de la misma fuente o dHash idéntico. Como la unión es transitiva (si A comparte lesión con B y B comparte dHash con C, las tres quedan juntas), se resolvió con componentes conectados (unión-búsqueda). En el conjunto curado, 10.946 imágenes tenían identificador de paciente, 13.213 de lesión y 15.641 identificador ISIC; el resultado fueron 11.997 grupos independientes.

Los grupos se repartieron en dos pasos con GroupShuffleSplit (Pedregosa et al., 2011): primero 75 % para entrenamiento y 25 % reservado, y luego el reservado en dos mitades para validación y prueba. En cada paso se generaron 500 particiones aleatorias y se eligió la que menos se alejaba de las proporciones globales, con el puntaje

$$S = 5\, e_{\text{clase}} + 2\, e_{\text{fuente-modalidad}} + e_{\text{tamaño}},$$

donde cada término es el error absoluto entre la proporción de la partición y la proporción global (Tabla 5). El mejor puntaje fue 0,138 en el primer paso y 0,423 en el segundo. El mayor desvío está en SCC, que quedó con 163 imágenes en validación y 147 en prueba.

Tabla 5.

Imágenes por clase y partición

Clase	Entrenamiento	Validación	Prueba	Total
Nevo	5.252 (75,0 %)	869 (12,4 %)	879 (12,6 %)	7.000
Melanoma	3.359 (74,6 %)	571 (12,7 %)	570 (12,7 %)	4.500
BCC	3.397 (75,5 %)	553 (12,3 %)	550 (12,2 %)	4.500
SCC	986 (76,1 %)	163 (12,6 %)	147 (11,3 %)	1.296
Total	**12.994 (75,1 %)**	**2.156 (12,5 %)**	**2.146 (12,4 %)**	**17.296**

Nota. Conteos de 02_dataset_audit.json (class_counts_by_split). Creado por autores.

La verificación no encontró coincidencias entre particiones por imagen, SHA-256, grupo, paciente, lesión ni identificador ISIC. El conjunto de prueba no se usó para entrenar, elegir épocas ni fijar el sesgo, el umbral o la TTA, que se decidieron en validación. Sí se evaluó más de una vez: en la serie de robustez se leyó en cada experimento y el Anexo K reporta todas esas lecturas.

G.10. Contenido del paquete y licencias

DERMATEC_KAGGLE_V2.tar ocupa 6.748.149.760 bytes y contiene tres elementos: la carpeta images/ con las 17.296 imágenes originales; manifest.csv, con una fila por imagen (clase, partición, fuente, modalidad, identificadores, grupo de partición, SHA-256, dHash y, cuando la fuente los publica, atribución y licencia); y pack_info.json, con los conteos y la política de partición. Cada corrida de entrenamiento comprueba el tamaño del archivo, los conteos por clase y partición y la ausencia de fugas.

Cada imagen se usa según la licencia de su fuente (Tabla 6). Como varias fuentes tienen licencia no comercial (CC BY-NC), el conjunto completo solo puede usarse con fines académicos no comerciales, que es el caso de este trabajo de grado. Las imágenes no se redistribuyen: el repositorio solo publica manifiestos, metadatos, licencias y código, y el paquete se mantiene privado en Kaggle. Un uso comercial futuro del prototipo exigiría revisar las licencias imagen por imagen.

Tabla 6.

Licencias de las fuentes

Fuente	Licencia	Dónde consta
ISIC Archive (3 subconjuntos)	Por imagen: CC0, CC BY o CC BY-NC	Columna copyright_license de los metadatos
ISIC 2019	CC BY-NC	Página del reto ISIC 2019
HAM10000	CC BY-NC 4.0	Tschandl et al. (2018)
MILK10k	CC BY-NC 4.0	Página DOI 10.34970/648456
DERM12345	CC BY	Página DOI 10.34970/705541
HIBA	CC BY	Página DOI 10.34970/559884

Nota. Páginas oficiales de cada fuente, consultadas en 2026. Creado por autores.

G.11. Limitaciones

- **Modalidad.** El 47 % de las imágenes no tiene la polarización documentada y solo el 4,3 % es polarizada sin contacto.
- **Imágenes de HIBA.** Las 227 imágenes con origen HIBA (1,3 % del total; 65 MEL, 114 BCC y 48 SCC) son fotografías clínicas y no dermatoscopías, porque las dermatoscopías de esa fuente ya habían entrado por el subconjunto ISIC de contacto polarizado. Están repartidas en entrenamiento, validación y prueba.
- **Fuentes sin nevos.** MILK10k, DERM12345 y HIBA aportan 3.960 imágenes (22,9 %) y ninguna es nevo. La red podría asociar rasgos propios de esas fuentes (dispositivo, encuadre, color) con malignidad. No se hizo un análisis del desempeño por fuente en el conjunto de prueba, que es la forma de comprobarlo.
- **Confirmación diagnóstica heterogénea.** Las imágenes de MILK10k tienen confirmación histopatológica; en las demás fuentes el diagnóstico puede venir de histopatología, seguimiento o consenso de expertos.
- **Criterio del SCC.** En MILK10k se exigió SCC invasivo y se excluyeron los SCC in situ; en las demás fuentes se respetó la etiqueta original, y la clase SCC final incluye 249 imágenes etiquetadas como SCC in situ.
- **Identificador de paciente incompleto.** Solo parte de las imágenes trae identificador de paciente. Los grupos por lesión, identificador ISIC y dHash reducen el riesgo de fuga, pero no reemplazan un identificador clínico.
- **Dominio del dispositivo.** Ninguna imagen proviene del capilógrafo de DERMATEC; todas son de dermatoscopios clínicos.

Referencias

Codella, N. C. F., Gutman, D., Celebi, M. E., Helba, B., Marchetti, M. A., Dusza, S. W., Kalloo, A., Liopyris, K., Mishra, N., Kittler, H., & Halpern, A. (2018). Skin lesion analysis toward melanoma detection: A challenge at the 2017 International Symposium on Biomedical Imaging (ISBI), hosted by the International Skin Imaging Collaboration (ISIC). En *2018 IEEE 15th International Symposium on Biomedical Imaging (ISBI 2018)* (pp. 168–172). IEEE. https://doi.org/10.1109/ISBI.2018.8363547

Combalia, M., Codella, N. C. F., Rotemberg, V., Helba, B., Vilaplana, V., Reiter, O., Carrera, C., Barreiro, A., Halpern, A. C., Puig, S., & Malvehy, J. (2019). *BCN20000: Dermoscopic lesions in the wild* (arXiv:1908.02288). arXiv. https://doi.org/10.48550/arXiv.1908.02288

International Skin Imaging Collaboration. (2019). *ISIC 2019 Challenge* [Conjunto de datos]. https://challenge.isic-archive.com/landing/2019/

International Skin Imaging Collaboration. (s. f.). *ISIC Archive* [Base de datos]. Recuperado el 9 de agosto de 2026, de https://www.isic-archive.com

MILK study team. (2025). *MILK10k* [Conjunto de datos]. ISIC Archive. https://doi.org/10.34970/648456

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830. https://www.jmlr.org/papers/v12/pedregosa11a.html

Ricci Lara, M. A., Rodríguez Kowalczuk, M. V., Lisa Eliceche, M., Ferraresso, M. G., Luna, D. R., Benitez, S. E., & Mazzuoccolo, L. D. (2023). A dataset of skin lesion images collected in Argentina for the evaluation of AI tools in this population. *Scientific Data, 10*, 712. https://doi.org/10.1038/s41597-023-02630-0

Tschandl, P., Akay, B. N., Rosendahl, C., Rotemberg, V., Todorovska, V., Weber, J., Wolber, A. K., Müller, C., Kurtansky, N., Halpern, A., Weninger, W., & Kittler, H. (2026). MILK10k: A hierarchical multimodal imaging-learning toolkit for diagnosing pigmented and nonpigmented skin cancer and its simulators. *Journal of Investigative Dermatology, 146*(2), 357–364.e7. https://doi.org/10.1016/j.jid.2025.06.1594

Tschandl, P., Rosendahl, C., & Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data, 5*, 180161. https://doi.org/10.1038/sdata.2018.161

Yilmaz, A., Yasar, S. P., Gencoglan, G., & Temelkuran, B. (2024). DERM12345: A large, multisource dermatoscopic skin lesion dataset with 40 subclasses. *Scientific Data, 11*, 1302. https://doi.org/10.1038/s41597-024-04104-3