Anexo J: Acondicionamiento de la imagen para la red neuronal

Este anexo describe cómo se prepara la imagen antes de entrar a los clasificadores, tanto en entrenamiento como en la aplicación, y la aumentación de datos usada para entrenar. El objetivo es que la red reciba en el dispositivo la imagen preparada con las mismas operaciones con que se entrenó.

J.1. Por qué la red recibe la imagen completa

El camino para el especialista (Anexo I) elimina el vello por inpainting, segmenta y recorta. Para la red no se hace nada de eso. El inpainting reemplaza píxeles por valores interpolados y un recorte con fondo negro crea un borde artificial de alto contraste; la red puede aprender esos patrones como si fueran rasgos de la lesión. Además, en la etapa de modelos multimodales se dio a la red la máscara, el recorte y descriptores radiómicos como entradas adicionales. El mejor modelo de esa etapa llegó a 0,777 de Macro-F1 en validación, por debajo de la meta de 0,80, y dependía de una segmentación que fallaba sobre todo en los carcinomas (ver Anexo K). Por eso a la red solo se le cambia el tamaño y el balance de color.

J.2. Cadena de acondicionamiento

La cadena tiene cuatro pasos. El primero solo se aplica en la aplicación; los tres siguientes son idénticos en entrenamiento, validación, prueba y aplicación:

1. **Color del equipo.** En la aplicación, la captura se corrige primero con la calibración de color del capilógrafo (ver Anexo N). Las imágenes del conjunto de datos no pasan por este paso porque vienen de dermatoscopios clínicos.
2. **Redimensionado.** La imagen RGB se lleva a 384 × 384 px con interpolación bilineal, sin conservar la relación de aspecto, y se convierte a float32 en el rango [0, 255]. La captura de 640 × 480 px (4:3) se estira en horizontal; las imágenes de entrenamiento pasan por la misma operación, cualquiera sea su proporción original.
3. **Constancia de color.** Una capa Shades of Gray dentro del modelo estima el color de la iluminación con la norma de Minkowski de orden p = 6 y lo neutraliza (Finlayson y Trezzi, 2004; Barata et al., 2015).
4. **Normalización de la red base.** EfficientNetV2 (Tan y Le, 2021) y MobileNetV3 (Howard et al., 2019) incluyen su propia capa de normalización de entrada (include_preprocessing), de modo que el modelo recibe valores entre 0 y 255.

Para cada canal c, la capa Shades of Gray calcula

$$e_c = \left(\frac{1}{N} \sum_x I_c\,(x)^p \right)^{1/p}, \qquad I'_c(x) = I_c(x)\,\frac{\bar{e}}{e_c}, \qquad \bar{e} = \frac{e_R + e_G + e_B}{3},$$

donde I_c está normalizada a [0, 1] y N es el número de píxeles. Con p = 1 el método equivale a Gray World y con $p \to \infty$ a White Patch; se usó p = 6, el valor empleado por Barata et al. (2015) en clasificación dermatoscópica.

Shades of Gray se adoptó por esa evidencia de la literatura. No se hizo una ablación: todos los modelos de la serie Z se entrenaron con la capa y no hay una corrida equivalente sin ella, de modo que su aporte en este conjunto no está medido. La calibración del paso 1 y esta capa corrigen cosas distintas. La calibración corrige el campo plano y el sesgo de color propios del capilógrafo, con una carta medida para ese equipo (Anexo N). Shades of Gray estima el iluminante de cada imagen, y es la única corrección de color que reciben también las imágenes de entrenamiento, que vienen de muchos dermatoscopios distintos.

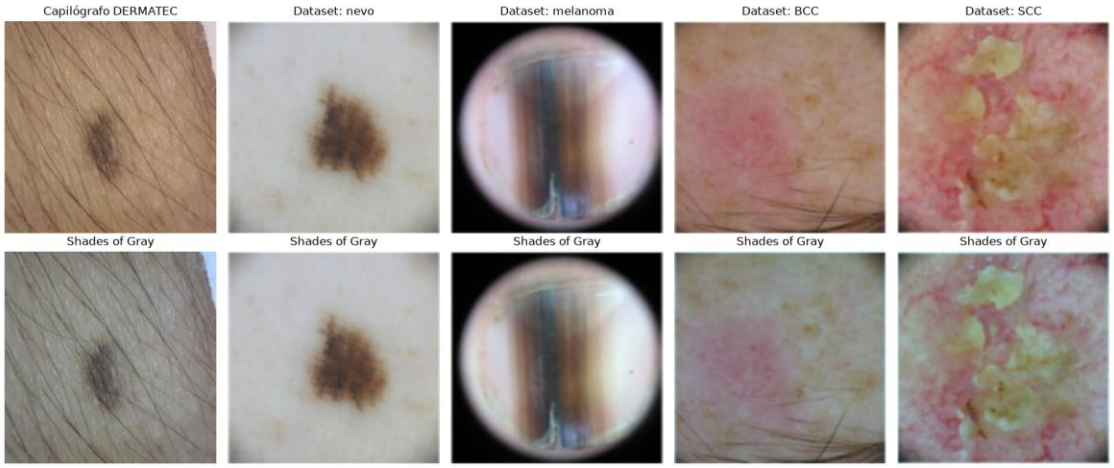
```
class ShadesOfGray(layers.Layer):
    """Constancia de color Shades of Gray (p = 6). Entrada y salida en [0, 255]."""
    def __init__(self, p=6, **kw):
        super().__init__(**kw); self.p = p
    def call(self, x):
        xn = keras.ops.clip(x / 255.0, 1e-6, 1.0)
        ilum = keras.ops.power(keras.ops.mean(keras.ops.power(xn, self.p), axis=(1, 2), keepdims=True),
1.0 / self.p)
        ganancia = keras.ops.mean(ilum, axis=-1, keepdims=True) / (ilum + 1e-6)
        return keras.ops.clip(x * ganancia, 0.0, 255.0)
```

Como la capa está registrada dentro del modelo, viaja en el archivo exportado: el PC y la Raspberry Pi aplican la misma operación sin código adicional. Quedan diferencias menores fuera del modelo: en entrenamiento la imagen se lee de una caché JPEG de calidad 95, mientras que en la aplicación la red recibe la captura calibrada guardada en PNG.

En modelos anteriores, la normalización de la red base se hacía con una capa Lambda que envolvía la función preprocess_input de MobileNetV1. Esa capa impedía recargar el modelo guardado fuera del cuaderno y exportarlo a TensorFlow Lite. Por eso, en la serie Z la normalización se dejó a cargo de la propia red base (include_preprocessing) y Shades of Gray se implementó desde el inicio como capa registrada.

Figura 1.

Efecto de Shades of Gray en una captura del capilógrafo y en imágenes del conjunto de datos



Nota. Fila superior: imagen redimensionada; fila inferior: salida de la capa. Creado por autores.

Tabla 1.

Formato de la imagen en cada etapa

Etapa	Dimensión	Tipo	Rango
Captura del capilógrafo	480 × 640 × 3	uint8	0–255
Entrada del modelo	1 × 384 × 384 × 3	float32	0–255
Después de Shades of Gray	1 × 384 × 384 × 3	float32	0–255
Salida	1 × 4	float32	probabilidades (suman 1)

Nota. Los modelos exportados a TensorFlow Lite guardan los pesos en 16 bits, pero reciben y entregan float32. Creado por autores.

J.3. Aumentación de datos

La aumentación se aplica solo a las imágenes de entrenamiento, en línea dentro de tf.data, sobre una copia local de las imágenes en caché (JPEG de calidad 95) para no leerlas de la nube en cada época. Incluye:

- rotaciones de 90° y espejo horizontal, porque la lesión no tiene orientación preferida;
- con probabilidad 0,5, un recorte cercano al centro que cubre entre el 15 % y el 60 % del área (zoom de 1,3× a 2,6×), con desplazamiento de hasta el 15 %; en caso contrario, un recorte suave del 80 % al 100 % del lado;
- con probabilidad 0,5 dentro del zoom, una degradación que reduce la resolución al 40–70 %, aplica compresión JPEG de calidad 55 a 90 para imitar la compresión MJPG de la cámara del capilógrafo, aplica con probabilidad 0,5 un desenfoque de 3 × 3 píxeles y multiplica cada canal por un factor aleatorio entre 0,9 y 1,1 (tinte de color);

- un desplazamiento de brillo de ±0,1 en la escala de 0 a 1, contraste de 0,85 a 1,15 y saturación de 0,8 a 1,2 (Shorten y Khoshgoftaar, 2019).

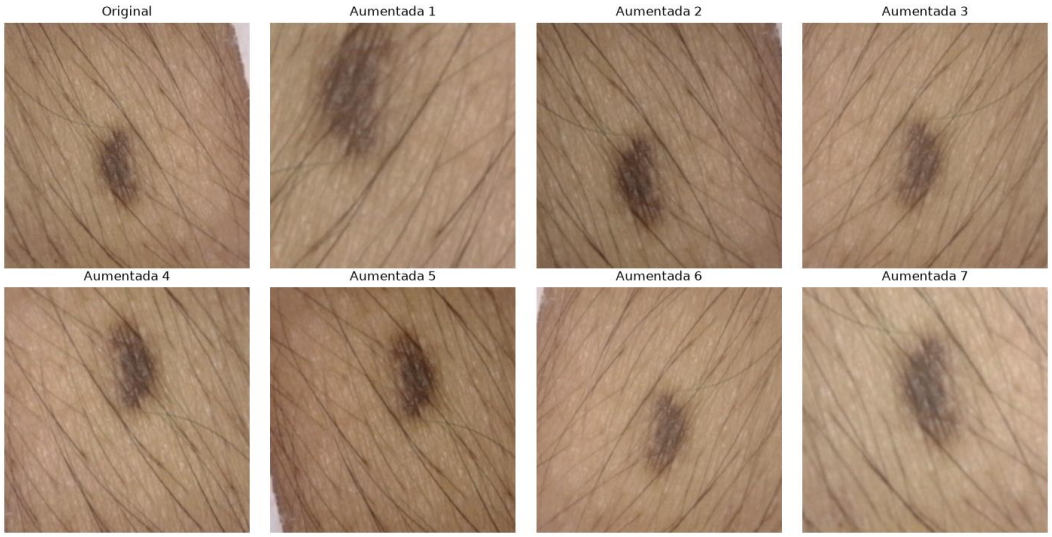
El tinte por canal altera el color que Shades of Gray y la calibración buscan neutralizar; forma parte de la degradación tipo capilógrafo y obliga a la red a tolerar variaciones pequeñas de color que esas correcciones no eliminan por completo.

El recorte con zoom y la degradación se agregaron cuando se encontró que las capturas del capilógrafo tenían más aumento que las del entrenamiento (ver Anexo K, donde se reporta cómo bajaron las falsas alarmas en lunares capturados con el equipo). El código siguiente muestra la función principal; el desenfoque y el tinte están dentro de zoom_capilografo. Para elegir la mejor época se usa la media del Macro-F1 de validación sobre la imagen original y sobre un recorte central con zoom 2×.

```
def aumentar(img):
    img = tf.image.rot90(img, tf.random.uniform([], 0, 4, tf.int32))
    img = tf.image.random_flip_left_right(img)
    img = tf.cond(tf.random.uniform([]) < ZOOM_P, lambda: zoom_capilografo(img), lambda:
recorte_suave(img))
    img = img / 255.0
    img = tf.image.random_brightness(img, 0.10)
    img = tf.image.random_contrast(img, 0.85, 1.15)
    img = tf.image.random_saturation(tf.clip_by_value(img, 0.0, 1.0), 0.8, 1.2)
    return tf.clip_by_value(img, 0.0, 1.0) * 255.0
```

Figura 2.

Siete versiones aumentadas de una captura



Nota. Creado por autores.

J.4. Predicción con volteos

En la aplicación, el modelo MobileNetV3 promedia su salida sobre cuatro versiones de la imagen: original, espejo horizontal, espejo vertical y ambos (TTA, test-time augmentation). Para EfficientNetV2 no se usa porque en validación no mejoró. La decisión de usarla o no se tomó en validación para cada modelo y queda guardada en config_dermatec.json.

J.5. Evolución del acondicionamiento

El acondicionamiento cambió con cada etapa del clasificador (Tabla 2). Los modelos multimodales recibían, además de la imagen, el recorte, la máscara y descriptores radiómicos, y normalizaban la imagen al rango [0, 1] fuera del modelo. En la serie Z se volvió a la imagen sola, se pasó a resoluciones mayores y la constancia de color se integró al modelo, de modo que el PC y la Raspberry Pi aplican la misma operación sin código adicional.

Tabla 2.

Evolución del acondicionamiento de la imagen

Etapa	Entradas	Resolución	Rango	Color
Réplicas de trabajos previos	Imagen	180 px	[0, 1]	Sin corrección
Modelo multimodal	Imagen, recorte, máscara, 33 descriptores y salida previa	224 px	[0, 1]	Sin corrección
Serie Z	Imagen	288 y 384 px	[0, 255]	Shades of Gray dentro del modelo
Modelos finales	Imagen corregida con la calibración del equipo	384 px	[0, 255]	Calibración del equipo + Shades of Gray

Nota. Creado por autores.

Referencias

Barata, C., Celebi, M. E., & Marques, J. S. (2015). Improving dermoscopy image classification using color constancy. *IEEE Journal of Biomedical and Health Informatics, 19*(3), 1146–1152. https://doi.org/10.1109/JBHI.2014.2336473

Finlayson, G. D., & Trezzi, E. (2004). Shades of gray and colour constancy. En *Proceedings of the Twelfth Color Imaging Conference* (pp. 37–41). Society for Imaging Science and Technology.

Howard, A., Sandler, M., Chu, G., Chen, L.-C., Chen, B., Tan, M., Wang, W., Zhu, Y., Pang, R., Vasudevan, V., Le, Q. V., & Adam, H. (2019). Searching for MobileNetV3. En *Proceedings of the IEEE/CVF International Conference on Computer Vision* (pp. 1314–1324). IEEE. https://doi.org/10.1109/ICCV.2019.00140

Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on image data augmentation for deep learning. *Journal of Big Data, 6*, 60. https://doi.org/10.1186/s40537-019-0197-0

Tan, M., & Le, Q. V. (2021). EfficientNetV2: Smaller models and faster training. En *Proceedings of the 38th International Conference on Machine Learning* (Vol. 139, pp. 10096–10106). PMLR. https://proceedings.mlr.press/v139/tan21a.html