Anexo K: Modelos de clasificación

Este anexo documenta todo el desarrollo del clasificador, desde la réplica de los trabajos previos de la Universidad hasta el modelo final: el protocolo de evaluación, cada familia de modelos con la idea que se probó, sus resultados, sus dificultades y la razón por la que se dejó o se mantuvo, la serie Z, el problema que apareció al usar el capilógrafo, la serie de robustez y los modelos finales Z.18 y Z.19 con su ensamble. Los entrenamientos se hicieron en Google Colab y Kaggle con TensorFlow y Keras (Abadi et al., 2016); los modelos finales se entrenaron sobre el conjunto DERMATEC_KAGGLE_V2.

K.1. Protocolo y métricas

El protocolo se fijó así: el conjunto de entrenamiento entrena, el de validación decide (época, sesgo por clase, umbral de malignidad, uso de predicción con volteos y modelo final) y el de prueba solo se reporta. La métrica principal es el Macro-F1 de cuatro clases, que pesa igual a cada clase y por tanto al SCC, la minoritaria:

$$\mathrm{F1}_k = \frac{2\,P_k\,S_k}{P_k + S_k}$$

$$\text{Macro-F1} = \frac{1}{4}\sum_{k=1}^{4} \mathrm{F1}_k$$

donde P_k es la precisión y S_k la sensibilidad de la clase k. La métrica clínica es la sensibilidad maligna, con P(maligno) = 1 − P(Nevo). El objetivo fija un Macro-F1 ≥ 0,80 y una sensibilidad ≥ 0,85 para las clases de mayor riesgo (melanoma, BCC y SCC). Como el equipo entrega una decisión benigna o maligna, la sensibilidad de cada una de esas clases se mide como la fracción de sus lesiones que el sistema marca como malignas, con cualquier subtipo. Esta medida es distinta de la sensibilidad de cuatro clases (recall), que además exige acertar el subtipo; las dos se reportan (Tablas 18 y 20).

Para la decisión benigna o maligna se toma como positiva la lesión maligna. Se cuentan los verdaderos positivos (TP, malignas detectadas), los falsos negativos (FN, malignas clasificadas como nevo), los verdaderos negativos (TN, nevos clasificados como benignos) y los falsos positivos (FP, nevos marcados como malignos). Con ellos se calculan:

$$\text{Sensibilidad} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}}$$

$$\text{Especificidad} = \frac{\text{TN}}{\text{TN} + \text{FP}}$$

$$\text{VPP} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

$$\text{VPN} = \frac{\text{TN}}{\text{TN} + \text{FN}}$$

donde VPP y VPN son los valores predictivos positivo y negativo. La sensibilidad dice qué parte de las lesiones malignas detecta el sistema y la especificidad, qué parte de los nevos deja como benignos. En una herramienta de apoyo pesa más la sensibilidad: un falso negativo puede retrasar la consulta con el especialista, mientras que un falso positivo solo lleva a una revisión adicional. Por eso, desde la serie J el umbral de malignidad se fijó en validación para alcanzar una sensibilidad de al menos 0,95 (0,96 en J2.1) y con ese umbral se reportó lo demás. Las réplicas y X.3 no se calibraron, y la serie E/K usó umbrales con otro criterio (sensibilidades de 0,896 a 0,908); cada tabla lo indica. El AUC (área bajo la curva ROC) resume qué tan bien se separan benignos y malignos sin depender del umbral.

La elección del modelo final y su calibración se hicieron solo con validación. En la serie de robustez el conjunto de prueba se evaluó en cada experimento, por eso en este anexo se reportan sus resultados para todos los modelos y no solo para el elegido. Antes de la versión V2, la prueba de 400 imágenes también se usó para analizar errores (J3 y especialista BCC–SCC), y esos valores se presentan como exploratorios. Sobre V2, la prueba se evaluó una vez con el primer ensamble Z.2 + Z.3 (K.10.2), luego en cada experimento de robustez (Tabla 13) y por último con los modelos finales congelados.

K.2. Resumen de las etapas

El clasificador pasó por siete etapas entre julio y septiembre de 2026 (Tabla 1 y Figura 1). En las primeras se usaron conjuntos de datos distintos al final: un banco de prueba común de 3.520 imágenes, un conjunto de trabajo de 10.200 imágenes de entrenamiento con validación y prueba de 400 cada una, la versión V1 (17.188 de entrenamiento y 2.903 de validación) y la versión final V2. Por eso los valores de etapas distintas no son comparables entre sí de forma directa; dentro de cada etapa sí lo son.

Tabla 1.

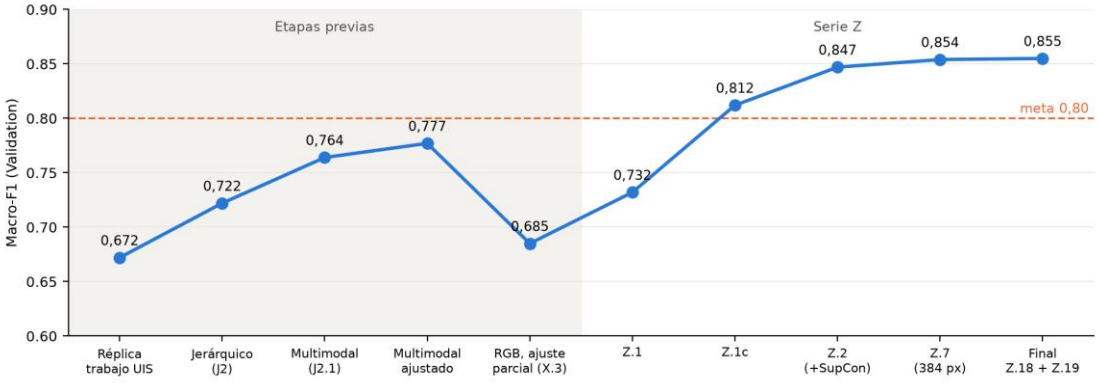
Etapas del desarrollo del clasificador

Etapa	Periodo	Modelos	Mejor Macro-F1	Lección
Antecedentes UIS	2021–2023	MobileNetV1, destilación, EfficientNetV2-B0 con contraste	Reportados en cada trabajo	Puntos de partida con tareas y datos distintos
Réplicas y banco de prueba	Julio	Diana/Helis, Andrew, Duván	0,672 (prueba, 400 imágenes)	Se definió un protocolo común de comparación
Línea base y ensamble	Julio	Codificador contrastivo, ensamble de tres cabezas, especialista BCC–SCC	0,747 (validación)	El 45,6 % de los errores era BCC↔SCC
Jerárquicos J1–J6	Julio–agosto	J2, J4, J5	0,746 (validación V1)	Sensibilidad maligna sobre 0,95; los subtipos no mejoraron
Serie E/K	Agosto	Contraste, descriptores radiómicos, pérdida focal, multiescala, mezcla de expertos	0,744 (validación V1)	Ningún modelo con más entradas o cabezas superó 0,744
Multimodal sobre V2	Agosto–septiembre	J2.1, J2.2, J2.1-R, FT72, POLISH	0,777 (validación V2)	La máscara falla en BCC y SCC; F1 del SCC ≤ 0,66
Auditorías X/Y	Septiembre	X.1–X.3, Y.1	0,685 (validación V2)	Fallas de lectura de datos y de ajuste fino (Tabla 9)
Serie Z y finales	Septiembre	Z.1–Z.19, ensamble Z.18 + Z.19	0,855 (validación) / 0,821 (prueba)	Ajuste fino completo, 384 px y escala fija por el acople

Nota. Macro-F1 de cuatro clases salvo que se indique otra cosa. Creado por autores.

Figura 1.

Evolución del Macro-F1 a lo largo del desarrollo



Nota. Macro-F1 de los modelos de referencia de cada etapa, desde la réplica del trabajo previo hasta el ensamble final; el primer punto es de prueba (400 imágenes) y los anteriores a la serie Z se midieron

sobre conjuntos de datos distintos al final. La línea discontinua marca la meta de 0,80. Creado por autores.

K.3. Antecedentes: trabajos previos de la UIS

El proyecto partió de tres trabajos de grado de la Universidad, que se tomaron como referencia para elegir arquitecturas y para comparar.

- **Diana Merchán y Helis Navarro (Merchán Vargas et al., 2021).** MobileNetV1 (Howard et al., 2017) a 224 px con pesos de ImageNet, promedio global, capa densa de 1.024 unidades, dropout de 0,25 y Adam con tasa de 1e-4, desplegada en una Raspberry Pi 3 B+. Reportaron F1 de 91,06 % y sensibilidad de 91,98 % en la tarea benigno/maligno.
- **Duván González y Sebastián Rivera (González Sandoval y Rivera Muñoz, 2022)**. Destilación de conocimiento (Hinton et al., 2015): un modelo profesor MobileNetV1 entrena un alumno residual pequeño para Android. Reportaron F1 de 0,9557 en binario y 0,8995 en tres clases; en el teléfono el alumno de tres clases bajó a 0,7290.
- **Andrew Rueda Rivera** (Rueda Rivera, 2023). Comparó ResNet50, MobileNetV2, Inception y EfficientNetV2 y eligió EfficientNetV2-B0 con una etapa de aprendizaje contrastivo supervisado (proyección de 128, temperatura 0,05), desplegado en una Raspberry Pi 4. Trabajaba a 180 px con cuatro clases (BCC, queratosis benigna, melanoma y nevo); en prueba obtuvo exactitud de 0,7135 y Macro-F1 de 0,69.

Ninguno de los tres clasificaba las cuatro lesiones del proyecto con el SCC como clase propia, y cada uno usaba datos, resoluciones y particiones distintas. Por eso sus valores no se pueden comparar directamente con los de DERMATEC.

K.4. Réplicas y banco de prueba común

Réplicas preliminares. Primero se intentó reproducir los tres trabajos. Se obtuvieron, por ejemplo, F1 de 0,842 con la red de Diana en una tarea binaria, Macro-F1 de 0,645 con la de Andrew sin la etapa contrastiva y valores muy bajos con la destilación (0,333 en binario). Al revisarlas se vio que eran adaptaciones y no réplicas exactas: cambiaban las clases, la resolución, la cabeza y los hiperparámetros, y había riesgo de imágenes repetidas entre HAM10000 e ISIC (Anexo G). Por eso se rehicieron con un protocolo común.

Banco de prueba común. Se armó un conjunto de cuatro clases con 680 imágenes por clase para entrenamiento, 100 para validación y 100 para prueba (3.520 en total), partido por paciente o lesión, y se entrenaron las tres líneas en las mismas condiciones (Tabla 2).

Tabla 2.

Réplicas de los trabajos previos en el banco de prueba común (400 imágenes de prueba)

Línea	Arquitectura y entrenamiento	Macro-F1	F1 binario	Observación
Diana/Helis	MobileNetV1, 224 px, base congelada, tasa 1e-4, 16 épocas	0,672	0,863	Sensibilidad maligna 0,923; recall de BCC 0,55
Andrew	EfficientNetV2-B0 con contraste, 180 px, clasificador sobre el encoder congelado	0,611	0,864	Recall de BCC 0,30: 44 BCC se clasificaron como SCC
Duván	Destilación profesor MobileNetV1 → alumno de 138.564 parámetros	---	---	El alumno colapsó: no reconoció ninguna imagen benigna

Nota. F1 binario: promedio del F1 de las clases benigna y maligna. En la tabla resumen del cuaderno la línea de Diana figura con 0,6592; el valor impreso por la evaluación es 0,6722. Creado por autores.

En el banco de prueba la destilación terminó con un Macro-F1 de 0,130: el alumno clasificó todas las imágenes como malignas (sensibilidad 1,00 y especificidad 0,00). Se intentó corregir entrenando primero el alumno solo, que llegó a un Macro-F1 de validación de 0,540 antes de detenerse; el entrenamiento era muy lento y faltaban el código, los pesos y la partición originales, por lo que se abandonó. La red de Diana se entrenó después con todo el conjunto disponible (34.410 imágenes) y pesos por clase, y alcanzó 0,670 en prueba, sin mejora frente al banco de prueba; además su exportación a TensorFlow Lite falló en la capa Lambda que envolvía preprocess_input de MobileNet, al combinarse con la política de precisión mixta.

Aunque la red de Diana obtuvo el mejor Macro-F1, el proyecto continuó con la línea de Andrew: tenía disponibles el código, el codificador contrastivo (encoder) y los pesos, era multiclase desde el diseño, incluía aprendizaje contrastivo y ya se había desplegado en una Raspberry Pi 4.

Los dos modelos que llegaron al final del banco de prueba fallaban en clases distintas. La red de Diana reconocía bien los nevos y era la más pareja entre clases, pero confundía el BCC; la de Andrew detectaba bien nevos y SCC, pero mandaba la mayoría de BCC a SCC (Tabla 3). La confusión entre BCC y SCC se repitió en los modelos posteriores (Tablas 7 y 18).

Tabla 3.

Sensibilidad por clase de las réplicas en el banco de prueba común

Línea	Nevo	Melanoma	BCC	SCC	Sensibilidad maligna	Especificidad
Diana/Helis	0,84	0,67	0,55	0,63	0,923	0,80
Andrew	0,91	0,56	0,30	0,76	0,883	0,91

Nota. Recall de cada clase sobre las 400 imágenes de prueba (100 por clase). La sensibilidad maligna y la especificidad se calcularon agrupando melanoma, BCC y SCC como malignos. Creado por autores.

K.5. Línea base DERMATEC y ensamble de tres cabezas

Sobre la línea de Andrew se construyó la primera versión propia (Macro-F1 de 0,670 en prueba con particiones de 2.720/400/400) y se amplió el conjunto de entrenamiento a 10.200 imágenes (5.000 nevos, 3.000 melanomas, 1.500 BCC y 700 SCC); la validación y la prueba siguieron siendo de 400 imágenes cada una (100 por clase). Leer las imágenes desde Google Drive hacía que cada época tardara unos 1.000 s, por lo que se pasó a una copia local en el entorno de Colab.

Con el codificador contrastivo se entrenaron tres cabezas de clasificación y se promediaron. El ensamble obtuvo 0,734 en validación y 0,685 en prueba, y una variante ponderada 0,747 y 0,679. El análisis de errores mostró que 57 de 125 errores (45,6 %) eran confusiones entre BCC y SCC, y que 70 errores eran unánimes entre las cabezas con confianza mayor a 0,70: el problema estaba en la representación aprendida y no en las cabezas.

Para atacar esa confusión se probó un especialista BCC–SCC con rasgos de color de la lesión segmentada. En un piloto, el canal b* de CIELAB separaba las dos clases (AUC de 0,898), pero con solo 19 casos y posible sesgo de iluminación. El ensamble con el especialista subió de 0,734 a 0,741 en validación, por debajo del modelo jerárquico J2, y su prueba quedó contaminada porque ese conjunto ya se había usado para analizar errores. Se descartó.

K.6. Modelos jerárquicos J1–J6

La idea de la serie J fue separar la decisión clínica de la clasificación del subtipo: primero nevo o maligno y, si es maligno, melanoma, BCC o SCC (Tabla 4). Todas las variantes usaron el codificador contrastivo de 180 px, se entrenaron con el conjunto de trabajo de 10.200 imágenes y se validaron en 400 (100 por clase).

Tabla 4.

Serie jerárquica J

Modelo	Idea	Resultado	Decisión
J1	Diseñar la jerarquía, revisar fugas y recuperar el encoder	Sin métricas	Base de la serie
J2	Encoder congelado con una cabeza binaria y una de subtipos; umbral 0,33 para sensibilidad ≥ 0,95	Validación: Macro-F1 0,746, sensibilidad 0,953, F1 de subtipos 0,751	Referencia de la etapa
J3	Evaluar J2 en el conjunto de prueba	Macro-F1 0,698, sensibilidad 0,937	Solo exploratorio: el conjunto ya se había usado
J4	Ajustar el encoder con contraste solo entre clases malignas	Validación: Macro-F1 0,735; recall de BCC de 0,73 a 0,65	Rechazado
J5	Usar recortes de la lesión como aumentación de los subtipos	Error de código; sin resultado	Abandonado
J6	Empaquetar J2 para la aplicación de escritorio	Paridad Colab–Windows a 10^{-7}	Desplegado

Nota. Entrenamiento con el conjunto de trabajo de 10.200 imágenes; validación y prueba de 400 imágenes (100 por clase) a 180 px. J3 usó un conjunto de prueba que ya se había consultado, por lo que solo es exploratorio. Creado por autores.

La jerarquía subió la sensibilidad maligna por encima de 0,95, pero no mejoró la separación de los subtipos, que seguía limitada por la confusión BCC↔SCC. J2 se mantuvo como referencia y, más adelante, como información previa del modelo multimodal.

J2 se entrenó con 10.200 imágenes y se validó en 400 (100 por clase). Tenía 6,6 millones de parámetros (31,2 MiB) y en validación detectó 286 de 300 lesiones malignas (14 falsos negativos). Su sensibilidad por clase fue de 0,85 en nevo, 0,70 en melanoma, 0,73 en BCC y 0,70 en SCC. En el conjunto de prueba (J3), frente al ensamble de tres cabezas, J2 subió la sensibilidad de 0,910 a 0,937 a cambio de bajar la especificidad de 0,890 a 0,870. Esa relación entre sensibilidad y especificidad se repitió en todas las etapas.

El conjunto definitivo DERMATEC_KAGGLE_V2, de 17.296 imágenes, se construyó después, en parte por lo aprendido en esta etapa. Con 100 imágenes por clase en validación, cada imagen mal clasificada movía un punto la sensibilidad de su clase, y el SCC tenía solo 700 imágenes de entrenamiento. En V2 se incluyeron todos los SCC disponibles (1.296), se agregaron carcinomas confirmados por histopatología de MILK10k y la validación pasó a 2.156 imágenes, con particiones separadas por paciente (Anexo G). Evaluado sobre V2, J2 bajó de 0,746 a 0,722 (K.8).

K.7. Serie E/K sobre la versión V1 del conjunto

Con la versión V1 del conjunto de datos y resolución de 224 px se probaron en paralelo varias ideas para romper el techo de J2 (Tabla 5).

Tabla 5.

Serie E/K sobre la versión V1 (validación)

Modelo	Idea	Macro-F1	Observación
E001	J2 a 224 px con balance por número efectivo de muestras	—	Solo se recuperó la primera época (0,605)
E002	Contraste supervisado con jerarquía	0,742	Sensibilidad 0,908; el contraste sobreajustó (mejor época: la 2)
E003	Máscaras y descriptores radiómicos; fusión con EfficientNetV2-B2 a 256 px	0.740	90,4 % de máscaras válidas, menos en BCC y SCC
K001	Imagen + 40 descriptores radiómicos	0,727	Rama visual sola 0,706; radiómica sola 0,534
K002	Lotes balanceados 8/8/8/8 y pérdida focal (Lin et al., 2017)	0,744	Sensibilidad 0,896; el mejor de V1
K003	Multiescala y agrupamiento bilineal	0,730	Estancado
K005	Imagen completa + recorte + 26 descriptores	0,739	Sin mejora
K006	Mezcla de expertos: 2 redes base y 5 cabezas (16,3 M parámetros)	0,715	Más complejo y peor

Nota. Valores de validación de la versión V1 del conjunto (2.903 imágenes) a 224 px, salvo E003 (256 px) y K006 (192 y 256 px). Los umbrales de esta serie no se fijaron para una sensibilidad de 0,95. K003 (0,730) es el mejor punto observado y es aproximado: la corrida se detuvo a mano por estancamiento. Las corridas sin valor no terminaron o no conservaron la salida final. Creado por autores.

Ningún modelo superó a J2. El F1 del SCC quedó entre 0,52 y 0,56, y bajar la tasa de aprendizaje por debajo de unos 3e-5 no aportó. Las variantes con más entradas o más cabezas no superaron a J2 (0,746).

En E002 se vio un patrón que se repitió en la serie: el clasificador sobre el codificador congelado llegó a 0,735 con sensibilidad de 0,883, y al abrir el codificador para ajuste fino empeoró a 0,705 y 0,795. El mejor codificador contrastivo salió en la segunda época, señal de que el contraste sobreajustaba rápido con pocas imágenes por clase. En K001 la rama radiómica sola llegó apenas a 0,534, lo que indicó que los descriptores de forma y color aportaban poco frente a la imagen.

K.8. Modelo multimodal sobre la versión V2

Con el conjunto final V2, J2 sin cambios bajó a un Macro-F1 de 0,722 en validación (sensibilidad 0,952; F1 del SCC 0,584), lo que mostró que el conjunto anterior sobreestimaba el desempeño.

K.8.1. J2.1

J2.1 combinaba una decisión en dos niveles: primero maligno o benigno con un umbral calibrado (0,435) y luego el subtipo entre melanoma, BCC y SCC. Recibía seis entradas: la imagen completa y el recorte de la lesión a 224 px, la máscara de segmentación, un vector de

33 descriptores radiómicos y de color, un índice de calidad de la máscara que reducía el peso del recorte cuando la segmentación era mala, y la salida de J2. Usaba una EfficientNetV2-B0 con 150 capas transferidas de J2 y cinco cabezas (6,5 M parámetros). Se entrenó dos épocas con la red base congelada (AdamW, 3e-4) y luego abriendo las últimas 48 capas (2e-5), con ReduceLROnPlateau y parada temprana; la salida final mezclaba 0,60 de J2 y 0,40 de J2.1. En validación alcanzó los valores de la Tabla 6 y la matriz de la Tabla 7. Aunque la sensibilidad maligna era alta, el Macro-F1 no llegó a la meta y la especificidad de los nevos fue de 0,776, lo que se traducía en muchas falsas alarmas.

Tabla 6.

Desempeño del modelo multimodal J2.1 en validación (2.156 imágenes)

Métrica	**Valor**
Exactitud (4 clases)	0,796
Macro-F1 (4 clases)	0,764
F1 ponderado	0,800
F1 binario de malignidad	0,910
Sensibilidad maligna	0,962
Especificidad (nevo)	0,776
Umbral de malignidad	0,435

Nota. F1 por clase: nevo 0,847, melanoma 0,778, BCC 0,800 y SCC 0,632. Creado por autores.

Tabla 7.

Matriz de confusión de J2.1 en validación

Clase real	**Nevo**	**Melanoma**	**BCC**	**SCC**
Nevo (869)	674	128	46	21
Melanoma (571)	41	457	53	20
BCC (553)	6	18	456	73
SCC (163)	2	1	32	128

Nota. Filas: clase real; columnas: predicción. Creado por autores.

J2.1 se instaló en la aplicación V5. Allí aparecieron dos problemas: la aplicación seguía usando el umbral de 0,33 en vez de 0,435, y con el capilógrafo marcó como malignas el 68,9 % de 74 capturas de lunares considerados benignos por examen clínico (ver K.11).

K.8.2. Variantes de J2.1

Se probaron cuatro variantes y un ensamble para mejorar J2.1 (Tabla 8).

Tabla 8.

Variantes del modelo multimodal en validación V2

Modelo	Idea	Umbral	Macro-F1	Sensibilidad	F1 SCC
J2.1	Modelo de partida	0,435	0,764	0,962	0,632
J2.2	Máscara y descriptores mejorados, 72 capas abiertas	—	—	—	—
J2.1-R	J2.1 con una máscara más rápida (94,3 % válidas)	0,380	0,763	0,969	0,626
FT72	J2.1-R con 72 capas abiertas, tasa de 1e-5 a 2,5e-6	0,445	0,772	0,960	0,655
POLISH	FT72 con tres épocas más a tasa fija 2,5e-6	0,440	0,775	0,960	—
Ensamble	0,4 FT72 + 0,6 POLISH	0,445	0,777	0,960	0,660

Nota. J2.2 mejoró la calidad de la máscara (94,4 % de máscaras válidas en las 15.150 imágenes de entrenamiento y validación, con una brecha de 4,19 puntos entre clases), pero no llegó a entrenar el clasificador. Creado por autores.

Cambiar la máscara movió el Macro-F1 en −0,002 y abrir más capas lo subió unas centésimas, hasta un techo de 0,777. El SCC seguía por debajo de 0,66.

K.9. Auditorías X y línea base Y

Antes de seguir agregando entradas se auditó lo que recibía la red.

- **X.1, máscaras.** En validación, el porcentaje de máscaras válidas era alto en todas las clases (91 a 95 %), pero la calidad media era menor en BCC y SCC (0,62 frente a 0,73–0,74 en nevo y melanoma). Al revisar 20 casos a mano aparecieron máscaras marcadas como válidas que en realidad cubrían una región mucho mayor que la lesión. El veredicto fue que la máscara no era una entrada confiable para la red.
- **X.2, entrada.** Se compararon la imagen original, un recorte de bordes y una corrección gamma. Las tres eran casi iguales (SSIM medio de 0,9987), así que se eligió la imagen RGB original.
- **X.3, línea base RGB.** EfficientNetV2-B0 a 224 px con la imagen sola, sin balance de clases. Llegó a 0,685 en validación, con sensibilidad de 0,903 y F1 del SCC de 0,424. El F1 de entrenamiento (0,682) era casi igual al de validación (0,669): la red no estaba aprendiendo lo suficiente. Por clase, X.3 detectó el 87,5 % de los BCC y el 62,9 % de los melanomas, pero solo el 32,5 % de los SCC: sin pesos por clase la red casi ignoraba la clase minoritaria.
- **Y.1, pesos por clase.** X.3 con pesos proporcionales a la raíz del inverso de la frecuencia (nevo 0,79, melanoma 0,98, BCC 0,98 y SCC 1,82), entrenada en dos fases

como X.3. Con 4 s por paso cada época tardaba unos 15 minutos; el Macro-F1 quedó en 0,685, en meseta, y se detuvo en la quinta época de la segunda fase.

Al revisar estos entrenamientos se encontraron fallas de ejecución que explicaban buena parte del estancamiento (Tabla 9).

Tabla 9.

Causas del estancamiento y corrección en la serie Z

Causa	Evidencia	Corrección en la serie Z
Lectura de imágenes lenta	Épocas de unos 1.000 s leyendo desde Drive; en X.3 e Y.1, 2 a 4 s por paso al decodificar imágenes de resolución completa	Copia local en caché, ya redimensionada (JPEG de calidad 95), y tf.data
Ajuste fino restringido	Se abrían 48 a 72 capas con tasas de 1e-5 a 2e-5; entrenamiento ≈ validación (subajuste)	Ajuste fino de toda la red, AdamW, calentamiento y coseno
Reducción de tasa agresiva	ReduceLROnPlateau bajaba la tasa en pocas épocas (X.3: a 9e-5 en la época 4) y la parada temprana cortaba justo después	Selección por Macro-F1 real y paciencia de 8 épocas
Máscaras inconsistentes	Calidad menor en BCC y SCC; máscaras válidas pero incorrectas (X.1)	La red recibe solo la imagen
Preprocesamiento fuera del modelo	Una capa Lambda impedía recargar el modelo guardado fuera del cuaderno; la exportación con precisión mixta fallaba	Preprocesamiento como capa registrada y exportación verificada
Datos y resolución	Conjuntos reducidos y 180–224 px	Todo el conjunto V2; 288 y 384 px

Nota. Resume lo encontrado al auditar los entrenamientos de las series J, E/K, X e Y, y el cambio que se hizo en la serie Z para cada causa. En los modelos anteriores, como la réplica de MobileNetV1, la normalización de la red base se hacía con una capa Lambda que envolvía preprocess_input de MobileNet; en la serie Z esa normalización quedó a cargo de la propia red base (include_preprocessing) y Shades of Gray se implementó como capa registrada (Anexo J). Creado por autores.

K.10. Serie Z

K.10.1. Arquitectura y receta

Cada modelo tiene una red base preentrenada en ImageNet, la capa Shades of Gray (Anexo J), dropout de 0,30 y una capa densa de 4 salidas con softmax. Durante el entrenamiento se agrega una cabeza de proyección (256 → 128) para la pérdida contrastiva, que se descarta al exportar.

La pérdida total es

$$\mathcal{L} = \mathcal{L}_{\text{CE}} + 0{,}3\,\mathcal{L}_{\text{SupCon}},$$

donde $\mathcal{L}_{\text{CE}}$ es la entropía cruzada con suavizado de etiquetas de 0,05 (Szegedy et al., 2016) y pesos por clase proporcionales a la raíz del inverso de la frecuencia, y $\mathcal{L}_{\text{SupCon}}$ es la pérdida contrastiva supervisada (Khosla et al., 2020):

$$\mathcal{L}_{\text{SupCon}} = \sum_{i} \frac{-1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp\left(z_i \cdot z_p / \tau\right)}{\sum_{a \neq i} \exp\left(z_i \cdot z_a / \tau\right)},$$

con z los vectores de proyección normalizados, P(i) las imágenes del lote con la misma clase que i y τ = 0,1. Esta pérdida acerca las representaciones de una misma clase y separa las de clases distintas.

```
def supcon_loss(y_true, z):
    z = tf.math.l2_normalize(tf.cast(z, tf.float32), axis=1)
    y = tf.argmax(y_true, axis=1); n = tf.shape(z)[0]; yo = tf.eye(n)
    logits = tf.matmul(z, z, transpose_b=True) / SUPCON_TEMP - 1e9 * yo
    log_prob = logits - tf.reduce_logsumexp(logits, axis=1, keepdims=True)
    pos = tf.cast(tf.equal(y[:, None], y[None, :]), tf.float32) - yo
    n_pos = tf.reduce_sum(pos, axis=1); valido = tf.cast(n_pos > 0, tf.float32)
    media_pos = tf.reduce_sum(pos * log_prob, axis=1) / tf.maximum(n_pos, 1.0)
    return -media_pos * valido * tf.cast(n, tf.float32) / tf.maximum(tf.reduce_sum(valido), 1.0)
```

Tabla 10.

Receta de entrenamiento de la serie Z

Componente	Configuración
Fase A	2 épocas con la red base congelada, tasa 1e-3
Fase B	Red base completa (normalización por lotes fija), AdamW con decaimiento de pesos 1e-2 (Loshchilov y Hutter, 2019)
Tasa de aprendizaje	Calentamiento dura una época al entrenar desde ImageNet y un cuarto de época al continuar desde otro modelo; la tasa máxima fue 2e-4 desde ImageNet, 8e-5 en Z.1C, 5e-5 en el cuaderno de Z.10–Z.17 y 4e-5 en Z.18 y Z.19
Lote	48 imágenes a 288 px y de 32 a 384 px
Selección de época	Macro-F1 real sobre las 2.156 imágenes de validación; parada si no mejora en 8 épocas
Exportación	Keras y TensorFlow Lite con pesos de 16 bits, sin la cabeza contrastiva; se verificó que ambos dan la misma salida

Nota. Receta de la serie Z. Los ajustes que parten de otro modelo (Z.1c, la serie de robustez Z.10–Z.17 y los modelos finales) no tienen fase A y usan una tasa máxima menor (ver Tablas 12 y 15). Creado por autores.

K.10.2. Resultados

Tabla 11.

Modelos de la serie Z en validación (2.156 imágenes)

Modelo	Red base	px	Contrastiva	Macro-F1	Sens. maligna	Espec.	F1 SCC	Tamaño
Z.1	EfficientNetV2-B0	288	No	0,732	0,950	0,720	0,578	11,8 MB
Z.1c	EfficientNetV2-B0	288	No	0,812	0,952	0,854	0,685	11,8 MB
Z.2	EfficientNetV2-B0	288	Sí	0,847	0,950	0,900	0,736	11,8 MB
Z.3	MobileNetV3-Large	288	Sí	0,841	0,950	0,879	0,724	6,0 MB
Z.4	ResNet50	288	Sí	0,825	0,952	0,890	0,695	47,1 MB
Z.6	EfficientNetV2-B0	384	Sí	0,846	0,950	0,888	0,748	11,8 MB
Z.7	EfficientNetV2-B0	384	Sí	0,854	0,951	0,899	0,752	11,8 MB
Z.8	EfficientNetV2-B2	384	Sí	0,845	0,952	0,878	0,738	17,5 MB
Z.9	MobileNetV3-Large	384	Sí	0,838	0,948	0,879	0,721	6,0 MB

Nota. Z.1 se detuvo en la época 15 por límite de GPU y se continuó como Z.1c. De Z.9 solo se conservó el Macro-F1. Sesgo por clase y umbral calibrados en validación. Creado por autores.

Frente a la línea base RGB de X.3, la mejora vino de la receta (0,685 → 0,812 → 0,847). Z.2 superó en 0,035 a Z.1c, pero esa comparación no aísla la pérdida contrastiva, porque Z.1c fue una continuación de Z.1 con una tasa máxima de 8e-5. Corregida la receta, la arquitectura influyó poco: ResNet50 quedó por debajo y pesa cuatro veces más, y EfficientNetV2-B2 no superó a B0. La variación entre corridas llegó a unos 0,02 (la misma MobileNet dio 0,841 en Colab y 0,820 en Kaggle), así que diferencias menores no se tomaron como mejoras.

Con estos modelos se hizo una primera selección: entre todas las combinaciones de hasta tres modelos, el ensamble Z.2 + Z.3 (0,861 en validación, 17,8 MB) empataba con la mejor combinación de tres y era más liviano. Se congeló y se evaluó una vez en prueba: Macro-F1 0,816, sensibilidad 0,926, especificidad 0,925 y AUC 0,973. Este ensamble se instaló en la versión V5.3 de la aplicación.

K.11. Cambio de dominio con el capilógrafo

Con la aplicación V5.3, lunares considerados benignos por examen clínico, sin confirmación histológica, salían como malignos: de 74 capturas tomadas con el acople corto, el 73 % se marcó como maligna, con una probabilidad de malignidad mediana de 0,70. Se descartó primero un error de software: el paquete reproducía la calibración de validación, el modelo en TensorFlow Lite coincidía con Keras y la aplicación cargaba el modelo correcto. La causa era un cambio de dominio: la imagen del capilógrafo tenía mucho más aumento que las de los dermatoscopios del conjunto de datos, además de desenfoque y otro tinte de color. Una simulación de zoom sobre validación lo confirmó: a 3× el Macro-F1 de Z.2 cae de 0,848 a 0,615 y el 38 % de los nevos pasa a maligno.

K.11.1. Serie de robustez Z.10–Z.17

Se hicieron ajustes finos desde Z.2 o Z.3 con una aumentación de zoom de 1,5× a 4× (área 0,06–0,45) y una degradación de resolución y compresión JPEG; el Anexo J describe la versión moderada que se usó después en Z.18 y Z.19. La época se eligió por el promedio del Macro-F1 de validación a 1× y 2× (Tabla 12). Z.10 y Z.11 no son válidos: el registro de la mejor época arrancó con el Macro-F1 del modelo de partida y nunca guardó una época nueva; se corrigió desde Z.12.

Tabla 12.

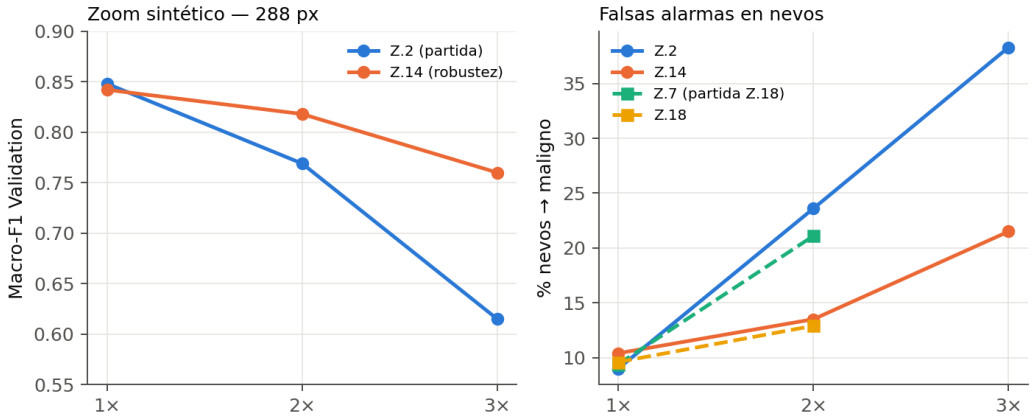
Serie de robustez en validación con zoom sintético

Modelo	Parte de	Macro-F1 1×	2×	3×	Nevos → maligno (1× / 2× / 3×)
Z.2	—	0,848	0,769	0,615	9,0 / 23,6 / 38,3 %
Z.3	—	0,841	0,772	0,625	10,4 / 20,3 / 38,0 %
Z.14	Z.2	0,842	0,818	0,760	10,4 / 13,5 / 21,5 %
Z.15	Z.2	0,849	0,821	0,774	9,6 / 14,4 / 21,9 %
Z.16	Z.2	0,850	0,825	0,774	8,5 / 13,1 / 20,9 %
Z.17	Z.3	0,830	0,818	0,777	10,2 / 12,5 / 17,8 %

Nota. Z.14: probabilidad de zoom 0,7 y área 0,06–0,45; Z.15: más épocas; Z.16: tasa 5e-5; Z.17: receta de Z.14 con MobileNet. Macro-F1 sin sesgo por clase; por eso Z.2 a 1× vale aquí 0,848 y en la Tabla 11, con sesgo calibrado, 0,847. Creado por autores.

Figura 2.

Efecto de la aumentación de escala sobre el Macro-F1 y las falsas alarmas en nevos



Nota. Izquierda: Macro-F1 de validación con zoom sintético de 1×, 2× y 3×. Derecha: porcentaje de nevos clasificados como malignos. Con la aumentación de escala (Z.14) el desempeño cae menos al aumentar el zoom. Creado por autores.

Tabla 13.

Serie de robustez en el conjunto de prueba

Modelo	Macro-F1 1×	2×	3×	Sens.	Espec.	AUC
Z.2 + Z.3	0,816	—	—	0,926	0,925	0,973
Z.14	0,819	0,778	0,728	0,936	0,886	0,969
Z.15	0,806	0,774	0,731	0,932	0,881	0,964
Z.16	0,800	0,778	0,729	0,928	0,875	0,962
Z.17	0,801	0,790	0,717	0,927	0,899	0,968

Nota. En esta serie el conjunto de prueba se evaluó para cada experimento, por lo que se reportan todos y la serie se presenta como evaluación de robustez. Creado por autores.

La aumentación hizo los modelos más robustos al zoom sin perder desempeño a 1×. Z.14 se instaló en la aplicación y bajó las capturas marcadas malignas de 73 % a 46 %, pero el problema no desapareció.

K.11.2. Normalización de escala por software

Se probó reducir la imagen cuando la lesión ocupaba más del cuadro que la mediana del entrenamiento (17 % del área), rellenando el borde por reflexión. La regla fijada antes de probar era adoptarla solo si mejoraba a 2× y 3× sin perder más de 0,01 a 1×. Empeoró en las tres escalas (Tabla 14): la reflexión crea copias en espejo de la lesión y lo que quedó fuera de la foto no se recupera. Se concluyó que la escala debía controlarse en la adquisición, lo que llevó al acople de distancia fija y a la calibración de la cámara (ver Anexo N).

Tabla 14.

Normalización de escala por software en validación

Zoom	Macro-F1 sin normalizar	Con normalización	Sensibilidad (sin → con)
1×	0,841	0,771	0,950 → 0,893
2×	0,813	0,751	0,943 → 0,887
3×	0,755	0,692	0,955 → 0,897

Nota. La normalización se aplicó a las imágenes de validación con zoom sintético. La regla para adoptarla era mejorar a 2× y 3× sin perder más de 0,01 a 1×; empeoró en las tres escalas. Creado por autores.

K.12. Modelos finales Z.18 y Z.19

K.12.1. Configuración

Con el acople la escala de la imagen quedó cerca de la del conjunto de datos, de modo que el zoom agresivo de Z.14 ya no era necesario. Se partió de los mejores modelos a 384 px de cada arquitectura (Z.7 y Z.9) y se ajustaron con un zoom moderado (Tabla 15). Como parten de un modelo ya entrenado, no tienen fase A y su calentamiento dura un cuarto de época. La degradación se aplica dentro del zoom: reduce la resolución al 40–70 %, comprime en JPEG con calidad de 55 a 90 y agrega, con probabilidad 0,5, un desenfoque de 3 × 3 píxeles, además de un tinte aleatorio de 0,9 a 1,1 por canal, para imitar la imagen del capilógrafo (Anexo J).

Tabla 15.

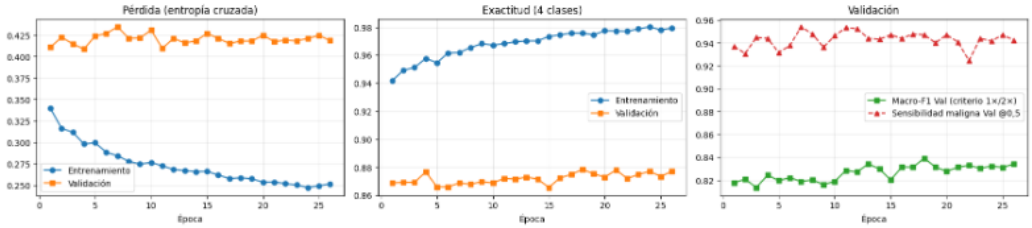
Configuración de los modelos finales

Parámetro	Z.18	Z.19
Parte de	Z.7	Z.9
Red base	EfficientNetV2-B0 (Tan y Le, 2021)	MobileNetV3-Large (Howard et al., 2019)
Parámetros	5,92 millones	3,00 millones
Entrada	384 × 384 px	384 × 384 px
Tasa máxima	4e-5	4e-5
Zoom	Probabilidad 0,5; área 0,15–0,60 (1,3× a 2,6×); desplazamiento 15 %	Igual
Degradación	Probabilidad 0,5 (resolución y JPEG)	Igual
Selección de época	Macro-F1 de validación a 1× y 2×	Igual
Pérdida	Entropía cruzada + 0,3 contrastiva	Igual
Predicción con volteos	No	Sí (4 vistas)
Tamaño TensorFlow Lite	11,8 MB	6,0 MB

Nota. Z.18 se detuvo en la época 26 y su mejor época fue la 18. Creado por autores.

Figura 3.

Curvas de entrenamiento de Z.18



Nota. Pérdida, exactitud y métricas de validación por época. Gráfica generada a partir del registro de entrenamiento en Kaggle. Creado por autores.

K.12.2. Calibración y regla de selección

En validación se calibraron un sesgo aditivo por clase sobre el logaritmo de las probabilidades y un umbral de malignidad que asegura una sensibilidad maligna de 0,95. La regla para elegir entre el ensamble y un modelo individual se fijó antes de ver los resultados: usar el ensamble solo si su Macro-F1 de validación supera al mejor individual en al menos 0,005; si no, el mejor individual, y en empate Z.19 por ser más liviano. El ensamble promedia las probabilidades de los dos modelos. Además, la predicción lleva un aviso de baja confianza cuando la lesión ocupa más del 60 % del campo o toca dos o más bordes (Anexo H).

Tabla 16.

Calibración en validación

Modelo	Macro-F1 validación	Umbral P(maligno)
Z.18	0,8496	0,475
Z.19	0,8484	0,520
Z.18 + Z.19	0,8554	0,545

Nota. Sesgo del ensamble (nevo, melanoma, BCC, SCC): 0; 0,15; 0; −0,45. Creado por autores.

El ensamble superó a Z.18 en 0,0058, por lo que la regla lo seleccionó. Esa ganancia es menor que la variación entre corridas (unos 0,02), así que por sí sola no demuestra que el ensamble sea mejor. La decisión se apoya en la regla fijada antes y en que el ensamble también tuvo la mayor especificidad (0,915 frente a 0,902 y 0,891) y el mayor AUC (0,968) en validación. La salida es jerárquica:

```
p_maligno = 1 - p[Nevo]
maligna   = p_maligno >= umbral            # 0,545
lp = np.log(p + 1e-9) + sesgo
clase = NOMBRES[1 + argmax(lp[1:])] if maligna else "Nevo"
```

Así la decisión binaria y la clase nunca se contradicen. Para el aviso de baja confianza se usa la entropía de la predicción,

$$H = -\sum_{k=1}^{4} p_k \log_2 p_k$$

que se compara con su percentil 95 en validación (1,26 bits).

K.12.3. Resultados

Tabla 17.

Desempeño de los modelos finales en entrenamiento, validación y prueba

Modelo	Conjunto	Macro-F1	Exactitud	Sens. maligna	Espec.	AUC
Z.18	Entrenamiento	0,996	0,996	0,998	0,996	1,000
Z.18	Validación	0,850	0,879	0,950	0,902	0,959
Z.18	Prueba	0,815	0,855	0,924	0,908	0,965
Z.19	Entrenamiento	0,998	0,998	0,999	0,997	1,000
Z.19	Validación	0,848	0,874	0,951	0,891	0,963
Z.19	Prueba	0,835	0,871	0,938	0,914	0,966
Z.18 + Z.19	Entrenamiento	0,999	0,999	0,999	0,999	1,000
Z.18 + Z.19	Validación	**0,855**	0,887	0,950	0,915	0,968
Z.18 + Z.19	**Prueba**	**0,821**	**0,870**	**0,934**	**0,920**	**0,970**

Nota. Cada modelo con su sesgo por clase y su umbral calibrados en validación. Los valores cercanos a 1 en entrenamiento muestran que las redes memorizaron ese conjunto. Datos de METRICAS_Z18_Z19_ensamble_train_val_test.csv. Creado por autores.

Tabla 18.

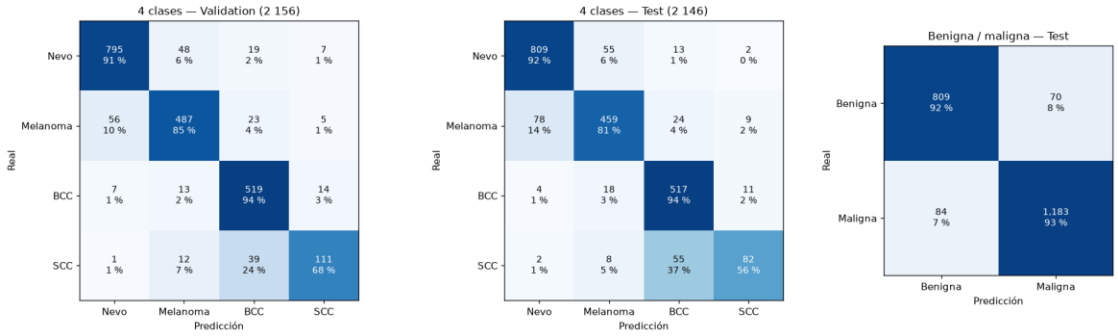
F1 y sensibilidad por clase del ensamble

Clase	F1 validación	F1 prueba	Sens. validación	Sens. prueba	Precisión prueba
Nevo	0,920	0,913	0,915	0,920	0,906
Melanoma	0,861	0,827	0,853	0,805	0,850
BCC	0,900	0,892	0,939	0,940	0,849
SCC	0,740	0,653	0,681	0,558	0,788
Macro	**0,855**	**0,821**	0,847	0,806	—

Nota. F1 y sensibilidad de cuatro clases (recall) con el umbral de 0,545; esta sensibilidad exige acertar el subtipo. El SCC es la clase más débil por su baja sensibilidad: el 37 % de los SCC de prueba se clasificó como BCC. Creado por autores.

Figura 4.

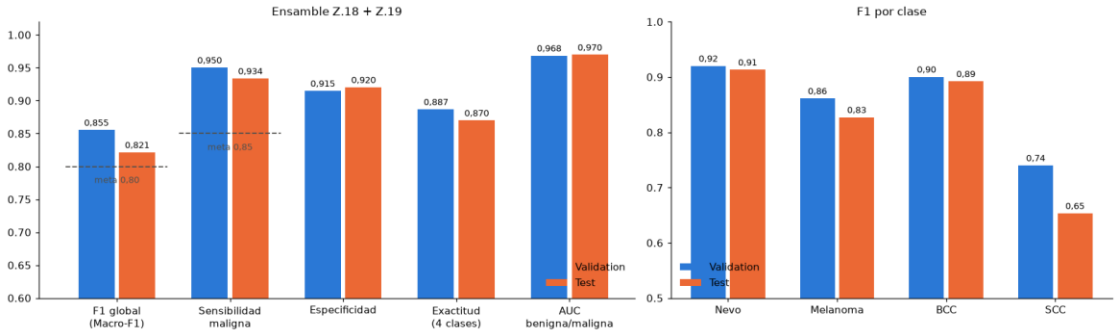
Matrices de confusión del ensamble en validación, prueba y prueba binaria



Nota. Filas: clase real; columnas: predicción. En la binaria de prueba: 809 benignos correctos, 70 falsas alarmas, 84 malignos no detectados y 1.183 malignos detectados. Creado por autores.

Figura 5.

Métricas globales y F1 por clase del ensamble



Nota. Las líneas punteadas marcan las metas del proyecto. Creado por autores.

K.12.4. Sensibilidad maligna y falsos negativos

La Tabla 19 resume la decisión benigna o maligna del ensamble. En prueba, de 1.267 lesiones malignas se detectaron 1.183 (sensibilidad de 0,934) y de 879 nevos quedaron como

benignos 809 (especificidad de 0,920). Cuando el sistema dice maligna acierta en el 94,4 % de los casos (VPP) y cuando dice benigna, en el 90,6 % (VPN).

Tabla 19.

Decisión benigna o maligna del ensamble Z.18 + Z.19

Conjunto	TP	FN	TN	FP	Sensibilidad	Especificidad	VPP	VPN	AUC
Validación	1.223	64	795	74	0,950	0,915	0,943	0,925	0,968
Prueba	1.183	84	809	70	0,934	0,920	0,944	0,906	0,970

Nota. Umbral de malignidad de 0,545, fijado en validación. TP, FN, TN y FP salen de las matrices de confusión de la Figura 4. Creado por autores.

En prueba la sensibilidad quedó en 0,934 (IC95 % de Wilson 0,919–0,946), un poco por debajo del 0,95 de validación, porque el umbral se ajustó con otro conjunto; sigue por encima de la meta de 0,85. Por clase, la detección como maligna en prueba fue de 0,863 en melanoma, 0,993 en BCC y 0,986 en SCC (Tabla 20), las tres por encima de la meta de 0,85 para las clases de mayor riesgo; en validación fue de 0,902, 0,987 y 0,994. La sensibilidad de cuatro clases (recall), que además exige acertar el subtipo, es menor: 0,805 en melanoma, 0,940 en BCC y 0,558 en SCC (Tabla 18). En el SCC la diferencia se debe a que el 37 % de sus lesiones se clasificó como BCC, que también es maligno. Los falsos negativos no se reparten igual entre clases (Tabla 20): casi todos son melanomas que salen como nevo, mientras que BCC y SCC casi nunca se confunden con un nevo.

Tabla 20.

Lesiones malignas clasificadas como nevo (FN) por clase

Clase	FN validación	% de la clase	FN prueba	% de la clase
Melanoma	56 de 571	9,8 %	78 de 570	13,7 %
BCC	7 de 553	1,3 %	4 de 550	0,7 %
SCC	1 de 163	0,6 %	2 de 147	1,4 %
Total	**64 de 1.287**	**5,0 %**	**84 de 1.267**	**6,6 %**

Nota. Calculado a partir de las matrices de confusión de la Figura 4. Creado por autores.

El melanoma clasificado como nevo es el error que más importa en la práctica. Se puede reducir bajando el umbral de malignidad, a cambio de más falsas alarmas, o agregando al entrenamiento melanomas pequeños y poco pigmentados, que son los que más se parecen a un nevo. Esa decisión debe tomarse con la especialista y con capturas del dispositivo que tengan diagnóstico confirmado.

Como desde la serie J el umbral se fijó para alcanzar la sensibilidad, esta se mantuvo alta; lo que cambió fue la especificidad, es decir, cuántas falsas alarmas había que aceptar para lograrla (Tabla 21). Con la misma sensibilidad, la especificidad pasó de 0,78–0,79 en los

modelos multimodales (0,72 en J2 sobre V2) a 0,92 en el modelo final: para detectar las mismas lesiones malignas, el modelo final marca menos de la mitad de nevos como malignos.

Tabla 21.

Sensibilidad y especificidad de los modelos principales de cada etapa

Modelo	Conjunto	Sensibilidad	Especificidad	Macro-F1
J2	Validación V1	0,953	—	0,746
J2 sin cambios	Validación V2	0,952	0,718	0,722
J2.1	Validación V2	0,962	0,776	0,764
FT72 + POLISH	Validación V2	0,960	0,785	0,777
X.3	Validación V2	0,903	—	0,685
Z.2	Validación V2	0,950	0,900	0,847
Z.2 + Z.3	Prueba V2	0,926	0,925	0,816
Z.14	Prueba V2	0,936	0,886	0,819
Z.18 + Z.19	Validación V2	0,950	0,915	0,855
Z.18 + Z.19	**Prueba V2**	**0,934**	**0,920**	**0,821**

Nota. X.3 no calibró el umbral para una sensibilidad de 0,95. Creado por autores.

K.12.5. Lectura de los resultados

- **Los datos limitan el desempeño.** Entrenamiento cercano a 1,0 frente a 0,85 en validación, con la pérdida de validación plana desde las primeras épocas: más épocas o más regularización no subieron validación (Z.15, Z.16). La mejora futura depende de más datos, sobre todo de SCC.
- **SCC es la clase débil.** El 37 % de los SCC de prueba se clasificó como BCC, con todos los modelos y arquitecturas. Ambos son carcinomas queratinocíticos con rasgos parecidos y SCC tiene 986 imágenes de entrenamiento. La confusión cambia el subtipo, no la decisión de malignidad.
- **Melanoma clasificado como nevo** (13,7 % en prueba; IC95 % 11,1–16,7 %) es la confusión más relevante clínicamente; la salida binaria la compensa en parte con sensibilidad de 0,934.
- **Z.19 por sí solo tuvo mejor Macro-F1 de prueba (0,835) que el ensamble (0,821), pero no se cambió.** La regla de selección se fijó sobre validación, y elegir con el conjunto de prueba lo convertiría en un conjunto de selección. La diferencia (0,014) está dentro de la variación entre corridas, y en prueba el ensamble tuvo mayor especificidad (0,920 frente a 0,914) y mayor AUC (0,970 frente a 0,966) que Z.19. Z.19 queda como alternativa si el ensamble resulta lento en la Raspberry Pi (ver Anexo L).

- **Frente a los modelos anteriores**, el ensamble final empata en prueba con Z.2 + Z.3 (0,821 frente a 0,816); su ventaja es que tolera mejor el zoom y trabaja a 384 px, la escala que entrega el acople.

K.13. Por qué EfficientNetV2 y MobileNetV3

Las dos redes tienen diseños distintos. EfficientNetV2 parte del escalado conjunto de profundidad, ancho y resolución de EfficientNet y usa bloques Fused-MBConv en las primeras capas para entrenar más rápido (Tan y Le, 2021). MobileNetV3 fue diseñada para teléfonos con búsqueda automática de arquitectura, bloques con atención por canal y la activación h-swish (Howard et al., 2019). Se esperaba que, al promediar dos arquitecturas distintas, parte de sus errores se compensara; la correlación entre sus errores no se midió. En validación el promedio subió el Macro-F1 de 0,850 a 0,855 y la especificidad de 0,902 a 0,915. Las dos juntas pesan 17,8 MB y son livianas para la Raspberry Pi 5 (tiempos en el Anexo L). ResNet50 (He et al., 2016) quedó por debajo y pesa 47 MB.

K.14. Problemas encontrados

Tabla 22.

Problemas del desarrollo del clasificador y solución

Problema	Causa	Solución
Épocas de unos 1.000 s	Lectura de imágenes desde Drive en cada época	Copia local y tf.data
Réplicas no comparables con los trabajos originales	Cambios de clases, resolución, cabeza e hiperparámetros	Banco de prueba común con 680/100/100 imágenes por clase
La destilación colapsó (Macro-F1 0,13; exactitud fija en 0,25 en otra corrida)	El alumno aprendía una sola clase; faltaban pesos y partición originales	Se abandonó la línea
Falló la exportación de la red de Diana a TensorFlow Lite	Política de precisión mixta	Exportación con pesos de 16 bits desde un modelo en precisión simple
Prueba contaminada en J3 y en el especialista BCC–SCC	El conjunto de prueba se había usado para analizar errores	Conjunto de prueba bloqueado desde la versión V2
J5 sin resultado	Error de código en la generación de recortes	Abandonado
K006 falló en el primer intento	Error de índice al combinar las cabezas	Corregido; el modelo igual quedó por debajo
La aplicación usaba un umbral distinto al calibrado	El umbral de J2 (0,33) quedó fijo al cambiar a J2.1 (0,435)	Umbral y sesgo leídos del archivo de configuración del modelo
Resultados de Kaggle perdidos	La sesión se cerraba sin guardar la salida	Archivo comprimido por experimento y versión guardada
Kaggle fallaba al montar Drive	Kaggle trae instalado el paquete de Colab	Detección del entorno por variable de Kaggle
Z.10 y Z.11 sin cambios	Monitor iniciado con el valor de partida	Corrección del monitor; se reportan como inválidos
Benignos clasificados como malignos con el capilógrafo	Cambio de escala	Serie de robustez, acople, calibración y Z.18/Z.19
Normalización de escala	La reflexión crea copias de la lesión	Rechazada con regla previa

Nota. Problemas registrados desde la réplica de los trabajos previos hasta los modelos finales, con la causa encontrada y la solución aplicada. Creado por autores.

Referencias

Abadi, M., Barham, P., Chen, J., Chen, Z., Davis, A., Dean, J., Devin, M., Ghemawat, S., Irving, G., Isard, M., Kudlur, M., Levenberg, J., Monga, R., Moore, S., Murray, D. G., Steiner, B., Tucker, P., Vasudevan, V., Warden, P., … Zheng, X. (2016). TensorFlow: A system for large-scale machine learning. En *12th USENIX Symposium on Operating Systems Design and Implementation (OSDI 16)* (pp. 265–283). USENIX Association.

González Sandoval, D. F., & Rivera Muñoz, S. (2022). *Diseño de una herramienta para la clasificación de imágenes de cáncer de piel en un sistema Android* [Trabajo de grado, Universidad Industrial de Santander]. Repositorio Noesis UIS. https://noesis.uis.edu.co/server/api/core/bitstreams/bc5e16d6-bf91-4f3e-bf6e-f7ef8cd57c42/content

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 770–778). IEEE. https://doi.org/10.1109/CVPR.2016.90

Hinton, G., Vinyals, O., & Dean, J. (2015). *Distilling the knowledge in a neural network* (arXiv:1503.02531). arXiv. https://doi.org/10.48550/arXiv.1503.02531

Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., & Adam, H. (2017). *MobileNets: Efficient convolutional neural networks for mobile vision applications* (arXiv:1704.04861). arXiv. https://doi.org/10.48550/arXiv.1704.04861

Howard, A., Sandler, M., Chu, G., Chen, L.-C., Chen, B., Tan, M., Wang, W., Zhu, Y., Pang, R., Vasudevan, V., Le, Q. V., & Adam, H. (2019). Searching for MobileNetV3. En *Proceedings of the IEEE/CVF International Conference on Computer Vision* (pp. 1314–1324). IEEE. https://doi.org/10.1109/ICCV.2019.00140

Khosla, P., Teterwak, P., Wang, C., Sarna, A., Tian, Y., Isola, P., Maschinot, A., Liu, C., & Krishnan, D. (2020). Supervised contrastive learning. En *Advances in Neural Information Processing Systems 33* (pp. 18661–18673). Curran Associates.

Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. En *Proceedings of the IEEE International Conference on Computer Vision* (pp. 2980–2988). IEEE. https://doi.org/10.1109/ICCV.2017.324

Loshchilov, I., & Hutter, F. (2017). SGDR: Stochastic gradient descent with warm restarts. En *International Conference on Learning Representations*. https://openreview.net/forum?id=Skq89Scxx

Loshchilov, I., & Hutter, F. (2019). Decoupled weight decay regularization. En *International Conference on Learning Representations*. https://openreview.net/forum?id=Bkg6RiCqY7

Merchán Vargas, D. P., Navarro Báez, H., Barrero Pérez, J. G., & Castillo Bohórquez, J. A. (2021). Diseño de una herramienta para la clasificación de imágenes de cáncer de piel utilizando Redes Neuronales Profundas (DNN). *Ciencia y Tecnología*, (21), 65–80. https://doi.org/10.18682/cyt.vi21.4612

Rueda Rivera, A. D. (2023). *Diseño de una herramienta para la detección de imágenes de cáncer de piel usando redes neuronales profundas (DNN)* [Trabajo de grado, Universidad Industrial de Santander]. Repositorio Noesis UIS. https://noesis.uis.edu.co/entities/publication/bfaff63d-6ebb-4e5a-a37b-b8faffbabdb8

Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., & Wojna, Z. (2016). Rethinking the Inception architecture for computer vision. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 2818–2826). IEEE. https://doi.org/10.1109/CVPR.2016.308

Tan, M., & Le, Q. V. (2021). EfficientNetV2: Smaller models and faster training. En *Proceedings of the 38th International Conference on Machine Learning* (Vol. 139, pp. 10096–10106). PMLR.